

Matemática 4 – 2025

TP 2 – Regresión Lineal

1) Suponga que un investigador cuenta con datos sobre la cantidad de espacio de estantería (x) dedicado a la exhibición de un producto particular y los ingresos por ventas (y) de ese producto. Es posible que el investigador desee adoptar un modelo para el cual la línea de regresión verdadera pase a través de $(0, 0)$.

a) ¿Cuál sería la ecuación de modelo mas apropiada para la misma?

b) Suponga que $(x_1, y_1), \dots, (x_n, y_n)$ son pares observados generados por el modelo del inciso anterior y deduzca el estimador de mínimos cuadrados de su coeficiente.

2) Considere los datos de la siguiente tabla:

x	2	3	5	9	13
y	8	10	18	30	40

A partir de estos datos, estime el coeficiente β de la ecuación de regresión $Y = 2 + \beta x + \varepsilon$ utilizando el método de mínimos cuadrados.

3) En un departamento de informática, un grupo de investigación dedicado al estudio de las comunicaciones por la red desea conocer la relación entre el tiempo de transmisión de un fichero y la información útil del mismo. Para ello se han hecho algunos experimentos en los que se enviaban paquetes de distintas longitudes (bytes) de información útil y se median los tiempos (en milisegundos) que tardaban desde el momento en que se enviaban hasta que llegaban al servidor. Los resultados del experimento se resumen en la siguiente tabla:

x (longitud)	100	110	120	150	190	200	225	265	280	300
y (tiempo)	52	75	62	61	84	98	110	94	100	135

a) Obtenga la estimación de mínimos cuadrados de la línea de regresión verdadera.

b) ¿Cuál es la estimación del tiempo de transmisión de un fichero cuando la longitud del paquete de información útil enviado es igual a 170?

c) ¿Utilizaría la línea de regresión estimada para predecir el tiempo de transmisión de un fichero cuando la longitud de paquetes de información útil enviado es igual a 500? ¿Por qué sí o por qué no?

d) ¿Cuánto aumenta el tiempo de transmisión por cada longitud?

4) Un estudiante de computación, que tiene una pequeña empresa de elaboración de software, llevó a cabo un estudio para determinar la relación entre el tiempo que tarda elaborando un software en días (x) y el ingreso obtenido por su venta en dólares (y). Se recolectaron los valores de estas variables para 14 software, obteniendo los siguientes datos:

x	2	3	5	9	10	16	19	20	24	27	32	41	55	60
y	100	200	250	400	500	850	930	900	1300	1360	1500	2050	2800	2900

a) Encuentre la ecuación de regresión lineal para el ingreso como función del tiempo de elaboración de un software.

b) ¿Aproximadamente, al elaborar un software, cuánto es el valor promedio del ingreso fijo (ingreso que no depende del tiempo de elaboración)?

c) ¿Aproximadamente, al elaborar un software, cuánto es el aumento promedio del ingreso por día de elaboración?

5) Demostrar las siguientes igualdades:

$$a) S_{xx} = \sum x_i^2 - \frac{(\sum x_i)^2}{n}$$

$$b) S_{yy} = \sum y_i^2 - \frac{(\sum y_i)^2}{n}$$

$$c) S_{xy} = \sum x_i y_i - \frac{\sum x_i \sum y_i}{n}$$

$$d) SS_R = S_{yy} - \hat{\beta}_1 S_{xy}$$

6) Determine si las siguientes relaciones son posibles o no:

$$a) \hat{\sigma}^2 = 0,2 \quad n = 102 \quad R^2 = 0,8 \quad S_{yy} = 100$$

$$b) \hat{y} = 7x + 4 \quad \bar{x} = 10 \quad \bar{y} = 64 \quad r = -0,8$$

$$c) \hat{\beta}_0 = 10,073 \quad \hat{\beta}_1 = -2,06 \quad \bar{x} = 8,5 \quad \bar{y} = 8,325$$

$$d) S_{xx} = 25,3133 \quad S_{yy} = 22,76 \quad SS_R = 5,7343 \quad S_{xy} = 40,75$$

7) A partir de un analisis de regresión sobre la relación entre el precio (en euros) "y" y el tamaño (en pulgadas) de pantallas TFT "x" $\in [15, 24]$, se conoce los siguientes estadísticos:

$$S_{xx} = 44,75 \quad \bar{x} = 18,75 \quad \hat{\beta}_0 = -279,1061$$

$$\sum x_i^2 = 1451 \quad \sum x_i y_i = 29009 \quad \sum y_i^2 = 590187$$

a) Calcular la recta de regresión para explicar el precio a partir del tamaño, indicar si es un buen ajuste y el grado de relación lineal entre las variables.

b) Realizar un grafico representativo mostrando la dispersión de los puntos alrededor de la recta de regresión estimada.

8) El analista de una fábrica de autos quiere desarrollar un modelo estadístico para predecir el tiempo de entrega (los días entre la compra del auto y la entrega real del mismo) de autos nuevos de fabricación especial. El cree que hay relación lineal entre las opciones del auto ordenado y su tiempo de entrega. Se selecciona una muestra aleatoria de 16 autos comprados, con los resultados que se presentan a continuación:

x = N° de opciones ordenadas y = Tiempo de entrega (en dias)

x	3	4	4	7	7	8	9	11	12	12	14	16	17	20	23	25
y	25	32	26	38	34	41	39	46	44	51	53	58	61	64	66	70

a) ¿Se puede predecir cuantos días se necesitarían para la entrega de un automóvil, si el analista considera que se puede presentar el caso de un auto con 24 opciones?

b) Estime un intervalo de confianza del 95% del tiempo promedio de entrega para todos los autos comprados en 15 opciones?


c) Pruebe al nivel de 5% que hay una relación significativa entre las variables x e y.

9) De un análisis de regresión realizada sobre un Dataset, el cual consiste en un pequeño relevamiento del tiempo que demandan las llamadas a servicio técnico de una empresa (x) y la cantidad de unidades de hardware reparadas (y), se sabe que el $IC(\beta_0) = (-0,4348 ; -0,4248)$, que la estimación de la pendiente es 12 veces el error que se comete al estimar la verdadera ordenada al origen con $\hat{\beta}_0$ y que la proporción de variación total observada no explicada por el modelo de regresión lineal es tan solo del 2%.

A partir de los datos proporcionados determinar:

- a) El error que se comete al estimar la verdadera ordenada al origen con $\hat{\beta}_0$
- b) La recta de regresión estimada
- c) La estimación de la varianza y la bondad del ajuste

10) Observando los siguientes gráficos de regresión y considerando las hipótesis $H_0: \beta_1 = 0$ vs $H_1: \beta_1 \neq 0$ para las mismas, responda cuál de las siguientes afirmaciones es correcta.



Seleccione una o más de una:

- ☐ No poder rechazar H_0 para el grafico (a) es equivalente a concluir que no hay relación lineal entre las variables y que el mejor estimador de y para cualquier x es $\bar{x}$.
- ☐ No poder rechazar H_0 para el grafico (b) es equivalente a concluir que no hay relación lineal entre las variables o bien que la verdadera relación entre las variables no es lineal.
- ☐ El test $H_0: \beta_0 = 0$ vs $H_1: \beta_0 \neq 0$ esta relacionada con la significación de la regresión.
- ☐ El test $H_0: \beta_1 = 0$ vs $H_1: \beta_1 \neq 0$ esta relacionada con la significación de la regresión.

11) Un virus informático ataco el disco duro (HDD) de una computadora y a partir de una investigación realizada por expertos sobre el tema se adoptó el modelo $Y = 10\beta_1x + \beta_0 + \varepsilon$ para determinar el porcentaje daño (y) producido por el virus en función de los días (x). A continuación se presenta algunos estadísticos obtenidos del analisis:

$$S_{xx} = 27768,357 \quad \bar{x} = 97,214 \quad \hat{\beta}_0 = -0,4298 \quad n = 14 \quad \hat{\beta}_1 = 0,0654$$

$$\sum x_i^2 = 160077 \quad \sum x_i y_i = 9885 \quad \sum y_i^2 = 27768,357$$

- a) Estime la Recta de regresión.
- b) ¿En cuantos días se pronostica un daño mayor al 90%?
- c) ¿Es posible que la recta verdadera pase por el origen? Realice una prueba de hipótesis adecuada con nivel de significancia 0.05 y responda.
- d) Si del intervalo de predicción se conoce $L_2 = 100$ (límite superior) y cometiéndose un error de ± 0.05 en el mismo ¿Sobre qué día fijo se realizó el intervalo?

12) Una Empresa de desarrollo de software le pide relacionar sus Ventas en función del número de pedidos de los tipos de software que desarrolla (Sistemas, Educativos y Automatizaciones Empresariales), para atender 10 proyectos en el presente año. En la Tabla representa Y (Ventas miles de S/.) e X (Nº pedidos de sistemas), W (Nº de pedidos de Aplicaciones Educativas) y Z (Nº de pedidos de Automatizaciones empresariales).

y	440	455	470	510	506	480	460	500	490	450
x	50	40	35	45	51	55	53	48	38	44
w	105	140	110	130	125	115	100	103	118	98
z	75	68	70	64	67	72	70	73	69	74

a) Definir las variables explicativas y respuesta.

b) Mediante un software a elección estime la ecuación de regresión múltiple para cumplir con el requerimiento de la empresa.

c) Calcule R_a^2 y r_a e interpretar los resultados.

13) En la Facultad de Sistemas Informáticos se quiere entender los factores de aprendizaje de los alumnos que cursan la asignatura de PHP, para lo cual se escoge al azar una muestra de 10 alumnos y ellos registran notas promedios en las asignaturas correlativas de Algoritmos, Base de Datos y Programación como se muestran en el siguiente cuadro.

PHP	Algoritmos	Base de Datos	Programación
13	15	15	13
13	14	13	12
13	16	13	14
15	20	14	16
16	18	18	17
15	16	17	15
12	13	15	11
13	16	14	15
13	15	14	13
13	14	13	10

a) Construir un modelo para determinar la dependencia que exista de aprendizaje reflejada en las notas de la asignatura de PHP, conociendo las notas de las asignaturas Algoritmos, Base de Datos y Programación.

b) ¿Cuál de las variables explicativas tiene una mayor correlación lineal con la variable respuesta?

14) Un fabricante de teléfonos celulares está probando dos tipos de baterías para ver cuánto duran con una utilización normal. La siguiente tabla contiene los datos provisionales:

Horas de uso diario	2	1,5	1	0,5
Vida aproximada (meses) Litio	3,1	4,2	5,1	6,3
Vida aproximada (meses) Alcalina	1,3	1,6	1,8	2,2

a) Desarrolle dos ecuaciones de estimación lineales, una para pronosticar la vida del producto basada en el uso diario con las baterías de litio y otra para las baterías alcalinas.

b) ¿Cuál de las dos estimaciones anteriores se ajusta mejor a los datos?

RESUMEN DE FORMULAS

Estadísticos de regresión

$$\bar{x} = \frac{\sum x_i}{n} \quad \bar{y} = \frac{\sum y_i}{n} \quad S_{xx} = \sum x_i^2 - \frac{(\sum x_i)^2}{n} \quad S_{yy} = \sum y_i^2 - \frac{(\sum y_i)^2}{n} \quad \hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

$$S_{xy} = \sum x_i y_i - \frac{\sum x_i \sum y_i}{n} \quad SS_R = SCE = S_{yy} - \frac{S_{xy}^2}{S_{xx}} \quad \hat{\sigma}^2 = \frac{SS_R}{n-2} \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad e_i = y_i - \hat{y}_i$$

$$R^2 = 1 - \frac{SS_R}{S_{yy}} \quad r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} \quad r = \sqrt{R^2} \quad \hat{\sigma}_a^2 = \frac{SS_R}{n-k-1} \quad R_a^2 = 1 - (1 - R^2) \left(\frac{n-1}{n-k-1} \right) \quad r_a = \sqrt{R_a^2}$$

Intervalos de Confianza y Predicción

$$\left(\hat{\beta}_0 - t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}; \hat{\beta}_0 + t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} \right)$$

$$\left(\hat{\beta}_1 - t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 / S_{xx}}; \hat{\beta}_1 + t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 / S_{xx}} \right)$$

$$\left(\hat{\beta}_0 + \hat{\beta}_1 x^* - t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}; \hat{\beta}_0 + \hat{\beta}_1 x^* + t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)} \right)$$

$$\left(\hat{Y}^* - t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}; \hat{Y}^* + t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)} \right)$$

Test de Hipótesis

$$T = \frac{\hat{\beta}_1 - \beta_{10}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

$$T = \frac{\hat{\beta}_0 - \beta_{00}}{\sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}}$$

Si $H_1: \beta_1 \neq \beta_{10}$ se rechaza H_0 si $|T| > t_{\frac{\alpha}{2}, n-2}$

Si $H_1: \beta_0 \neq \beta_{00}$ se rechaza H_0 si $|T| > t_{\frac{\alpha}{2}, n-2}$

Si $H_1: \beta_1 > \beta_{10}$ se rechaza H_0 si $T > t_{\alpha, n-2}$

Si $H_1: \beta_0 > \beta_{00}$ se rechaza H_0 si $T > t_{\alpha, n-2}$

Si $H_1: \beta_1 < \beta_{10}$ se rechaza H_0 si $T < -t_{\alpha, n-2}$

Si $H_1: \beta_0 < \beta_{00}$ se rechaza H_0 si $T < -t_{\alpha, n-2}$

Si $P - \text{valor} > 0.05$ entonces no se rechaza H_0 con nivel de significancia 0.05

Si $P - \text{valor} \leq 0.05$ entonces se rechaza H_0 con nivel de significancia 0.05