

Matemática 4

Resumen teorías

Clase 1 - Cálculo en dos o más variables	5
Función de n variables	5
Curvas de nivel	5
Función de 2 variables	5
Límite	5
Teorema del sandwich o encaje	6
Propiedades de los límites	7
Existencia de un límite	7
Coordenadas polares	8
Continuidad	9
Diferenciabilidad	11
Derivadas parciales	11
Diferenciabilidad para funciones de dos variables	12
¿Una función es diferenciable?	14
Propiedades	14
Plano tangente	15
Linealización	15
Vector gradiente y derivada direccional	15
Dirección de máximo crecimiento	16
Extremos de funciones de dos variables	17
Punto crítico	17
Teorema de clairaut	18
Criterio de las derivadas segundas	19
Descenso del gradiente	19
Algoritmo	21
Clase 2 - Regresión lineal	22
Regresión lineal simple	22
Método de mínimos cuadrados	25
Recta de regresión estimada	27
Estimación de 2	28
Coeficiente de determinación	29
Explicación de un modelo	30
Coeficiente de correlación lineal	33
Propiedades de los estimadores	34
Inferencias estadísticas	35
Sobre 1	35
Intervalo de confianza	35
Test de hipótesis	36
Sobre 0	37
Intervalo de confianza	37

Test de hipótesis	37
Intervalo de confianza para la respuesta media	38
Intervalo de predicción para valores futuros de Y	40
Regresión lineal múltiple	41
Varianza y coeficiente de determinación	44
Clase 3 - Teoría de números	46
Ley de monotonía de la suma y producto en enteros	46
Divisibilidad en enteros	46
Propiedades	46
Algoritmo de división	47
Cambio de base	47
Enteros primos	48
Criba de eratóstenes	48
Teorema fundamental de la aritmética	48
Máximo común divisor (MCD)	49
Algoritmo de euclides	49
Identidad de Bézout	50
Coprimos	50
Mínimo común múltiplo	51
Números reales	51
Números racionales	52
Densidad	52
Números irracionales	52
Propiedades	53
Números complejos	53
Suma	54
Opuesto y resta	54
Producto	55
Inverso y cociente	55
Potencias de complejos	56
Representaciones	56
Par ordenado	56
Módulo y argumento	57
Forma trigonométrica	58
Forma exponencial	58
Forma polar	59
Operaciones en forma exponencial	59
Producto y cociente	59
Potencia	60
Raíces n-ésimas	60
Clase 4 - Relaciones entre conjuntos	62
Dominio e imagen	63
Relación inversa	63
Composición	63

Matriz de una relación	64
Relaciones binarias en un conjunto	64
Propiedades	64
Reflexividad	64
Simetría	65
Antisimetría	65
Transitividad	65
Relaciones de orden	65
Orden parcial y total	66
Orden producto y orden lexicográfico	66
Conjuntos ordenados	67
Elementos extremos	67
Relaciones de equivalencia	67
Clases de equivalencia	68
Conjunto cociente	68
Partición	68
Relación de congruencia	70
Clase 5 - Estructuras algebraicas	74
Bien definida	74
Propiedades de las operaciones binarias	74
Conmutativa	74
Asociativa	74
Elemento neutro	74
Elemento inverso	74
Potencia	75
Tipos de estructuras	75
Grupoide	75
Semigrupo	75
Monoide	75
Grupo	75
Anillo	76
Propiedades de los grupos	76
Grupo producto	76
Grupo cíclico	76
Orden	76
Subgrupo	77
Morfismos de grupos	78
Núcleo e imagen	78
Aritmética modular	78
Operaciones	79
Suma	79
Producto	79
Elementos invertibles	79
Cosas raras	80

Aplicaciones a la criptografía	80
RSA	80
Clase 6 - Álgebra lineal	82
Espacio vectorial	82
Propiedades a cumplir	82
Subespacio vectorial	83
Combinación lineal	84
Espacio generado	84
Conjunto generador	85
Independencia lineal	85
Base de un espacio vectorial	86
Dimensión	86
Transformaciones lineales	87
Propiedades	87
Imagen y núcleo	88
Inyectiva y sobreyectiva	88
Obtener una transformación a partir de la base	89
Representación matricial	89

Clase 1 - Cálculo en dos o más variables

Función de n variables

Una función real f de n variables es una regla que asigna a cada n -upla de números reales $(x_1, x_2, \dots, x_n)$ un único número real $f(x_1, x_2, \dots, x_n)$.

$$f : D \subset \mathbb{R}^n \rightarrow \mathbb{R}$$

Curvas de nivel

Se llama *curva de nivel k* de una función f de dos variables al conjunto de todos los puntos del dominio de la función con coordenadas (x, y) tales que $f(x, y) = k$, donde k es una constante que pertenece a la imagen de f . Llamando C_k a la curva de nivel k , entonces para cada $k \in Im(f)$.

$$C_k = \{(x, y) : (x, y) \in Dom(f); f(x, y) = k\}$$

Función de 2 variables

Una función real f de dos variables es una regla que asigna a cada par ordenado de números reales (x, y) un único número real $f(x, y)$.

En este caso el dominio de f , $Dom(f)$, que es el subconjunto de $\mathbb{R}^2$.

Límite

Intuitivamente, la idea de límite de f cuando $x \rightarrow x_0$ es igual a L significa que, a medida que x se acerca a x_0 , los valores que va tomando f se acercan cada vez más al valor de L .

Al ser f una función de una variable, el dominio está incluido en la recta real (es unidimensional), sólo hay dos direcciones o caminos posibles para llegar a x_0 : desde la izquierda o desde la derecha. Si el límite por la izquierda es distinto del límite por la derecha, entonces el límite de la función cuando $x \rightarrow x_0$ no existe, mientras que si ambos límites laterales existen y coinciden, entonces la función tiene ese límite.

Para funciones de varias variables el concepto de límite es similar al visto para una variable, aunque el cálculo es un poco más complejo.

Se dice que una función de dos variables $f(x, y)$ tiene límite L (un número real fijo) cuando $(x, y) \rightarrow (x_0, y_0)$, si para todos los puntos (x, y) cercanos al punto (x_0, y_0) , los valores $f(x, y)$ son arbitrariamente próximos al número L .

La definición es similar a la del límite funcional para una variable. Sin embargo, para el caso de una función de dos variables (definida sobre un dominio bidimensional $D \subset \mathbb{R}^2$), el punto (x, y) podrá acercarse al punto (x_0, y_0) desde muchas direcciones. De hecho, hay infinitas maneras de acercarse a un punto en el plano.

Definición 1.7. Se dice que una función $f(x, y)$ tiene límite L si cuando (x, y) tiende a (x_0, y_0) la función $f(x, y)$ se acerca al valor L y se escribe $\lim_{(x,y) \rightarrow (x_0,y_0)} f(x, y) = L$

Formalmente el límite existe si dado un número ϵ existe un número $\delta > 0$, tal que $\forall (x, y) \in \text{Dom}(f)$, entonces

$$0 < \sqrt{(x - x_0)^2 + (y - y_0)^2} \leq \delta \rightarrow |f(x, y) - L| < \epsilon$$

Si se eligen 2 o tres caminos y son diferentes, entonces no existe el límite, pero si son iguales, eso no es suficiente para probar la existencia de límite

Teorema del sandwich o encaje

Teorema 1.9. Si existen funciones $g(x, y)$ y $h(x, y)$ tales que

$$g(x, y) \leq f(x, y) \leq h(x, y)$$

$\forall (x, y) \neq (x_0, y_0)$ en un disco con centro en (x_0, y_0) , y si

$$\lim_{(x,y) \rightarrow (x_0,y_0)} g(x, y) = \lim_{(x,y) \rightarrow (x_0,y_0)} h(x, y) = L$$

entonces

$$\lim_{(x,y) \rightarrow (x_0,y_0)} f(x, y) = L$$

Propiedades de los límites

Sea $c \in \mathbb{R}$ una constante, y sean $f(x, y)$ y $g(x, y)$ dos funciones reales de dos variables tales que existen los siguientes límites $\lim_{(x,y) \rightarrow (x_0,y_0)} f(x, y) = L$ y $\lim_{(x,y) \rightarrow (x_0,y_0)} g(x, y) = M$. Entonces se cumplen las siguientes propiedades:

- $\lim_{(x,y) \rightarrow (x_0,y_0)} (f(x, y) + g(x, y)) = L + M$
- $\lim_{(x,y) \rightarrow (x_0,y_0)} cf(x, y) = c.L$
- $\lim_{(x,y) \rightarrow (x_0,y_0)} (f(x, y) . g(x, y)) = L.M$
- $\lim_{(x,y) \rightarrow (x_0,y_0)} \frac{f(x, y)}{g(x, y)} = \frac{L}{M}$ si $M \neq 0$

Además, si $M = 0$ y $L \neq 0$ entonces $\lim_{(x,y) \rightarrow (x_0,y_0)} \frac{f(x, y)}{g(x, y)}$ no existe.

Existencia de un límite

Ver ejemplos 1.11 (pág. 11)

Se puede hacer siguiendo los siguientes pasos:

1. Si está definida en el punto, listo, EXISTE y se calcula por evaluación directa
2. Si no está definida en el punto:
 - a. Cuando probamos por límites iterados (x fija e 'y' acercándose a y_0 , y viceversa) y son distintos los límites, entonces el límite NO EXISTE
 - b. Si es igual:
 - i. Miramos si al acercarnos por una recta el límite es igual al resultado de iterados, y si es igual en todos los casos (no depende de la pendiente o algo así). Si alguna de las dos cosas no se cumple, el límite NO EXISTE
 - ii. Si ambas cosas se cumplen, entonces:
 1. Podemos probar lo mismo pero usando una curva en lugar de una recta, si tiende a otro valor que en los casos anteriores, el límite NO EXISTE

2. Si tiende al mismo valor:

- a. Hay que aplicar teorema del encaje o la definición, lo que nos va a asegurar la existencia o no del límite

Coordenadas polares

$$x = r \cos(\theta), \quad y = r \sin(\theta) \text{ y } x^2 + y^2 = r^2$$

Podemos decir que $(x, y) \rightarrow (0, 0)$, por ejemplo, equivale a decir (en coordenadas polares) $r \rightarrow 0$ (independientemente del valor de θ).

Otra cosa que podemos hacer para definir la existencia de un límite es usar coordenadas polares que si terminan siendo independientes del valor del ángulo, implican que el límite es el resultado obtenido:

Ejemplo 1.12. Sea $f(x, y) = \frac{xy^2}{x^2 + y^2}$, queremos calcular el $\lim_{(x,y) \rightarrow (0,0)} f(x, y)$

Recordando que en coordenadas polares tenemos que $x = r \cos(\theta)$ y $y = r \sin(\theta)$,

entonces podemos escribir: $x^2 + y^2 = r^2 \cos^2(\theta) + r^2 \sin^2(\theta) = r^2 \{\cos^2(\theta) + \sin^2(\theta)\} = r^2$,
luego,

$$\frac{xy^2}{x^2 + y^2} = \frac{r \cos(\theta) r^2 \sin^2(\theta)}{r^2 \cos^2(\theta) + r^2 \sin^2(\theta)} = \frac{r^3 \cos(\theta) \sin^2(\theta)}{r^2} = r \cos(\theta) \sin^2(\theta)$$

por lo cual:

$$\lim_{(x,y) \rightarrow (0,0)} \frac{xy^2}{x^2 + y^2} = \lim_{r \rightarrow 0} r \cos(\theta) \sin^2(\theta) = 0$$

independientemente del valor de θ

Continuidad

Definición 1.13. Una función real $f(x, y)$ es continua en un punto (x_0, y_0) si:

- $\exists f(x_0, y_0)$.
- $\exists \lim_{(x,y) \rightarrow (x_0,y_0)} f(x, y)$
- Se verifica que $\lim_{(x,y) \rightarrow (x_0,y_0)} f(x, y) = f(x_0, y_0)$

Es decir, si la función está definida en ese punto, existe el límite en ese punto y ambos son iguales.

La continuidad de una función en un punto significa, intuitivamente, que si se cambia el punto (sus coordenadas) en una pequeña cantidad, entonces el valor de la función cambia en una pequeña cantidad.

Teorema 1.14. Si c es un número real y f y g son funciones continuas en (x_0, y_0) , entonces las funciones siguientes son continuas en (x_0, y_0) :

1. *Múltiplo escalar:* cf
2. *Suma (y diferencia):* $f + g$
3. *Producto:* fg
4. *Cociente:* $\frac{f}{g}$, si $g(x_0, y_0) \neq 0$.

Teorema 1.15. Si h es continua en (x_0, y_0) y g es continua en $h(x_0, y_0)$, entonces la función compuesta $(g \circ h)(x, y) = g(h(x, y))$ es continua en (x_0, y_0) .

Ejemplo 1.16. Estudiar la continuidad de las funciones: $f(x, y) = \frac{5yx^2}{x^2+y^2}$ y $g(x, y) = \frac{x^2-y^2}{x^2+y^2}$

El $\text{Dom}(f) = \mathbb{R}^2 - (0, 0)$ y observamos que f es continua en todos los puntos de su dominio, puesto que es una función racional.

Ahora nos preguntamos si podemos extender esta función de manera tal de lograr una (nueva) función $F(x, y)$ continua en todo $\mathbb{R}^2$ y que coincida con $f(x, y)$ siempre salvo en el origen.

Para ello lo que hace falta es dar un valor apropiado para la función F en el origen: el valor apropiado será el límite de f en el origen, que ya vimos que existe.

$$F(x, y) = \begin{cases} \frac{5yx^2}{x^2+y^2} & \text{si } (x, y) \neq (0, 0) \\ 0 & \text{si } (x, y) = (0, 0) \end{cases}$$

Dado que g es una función racional, es continua en su dominio que es el conjunto $\text{Dom}(g) = \mathbb{R}^2 - (0, 0)$. La función g es discontinua en $(0, 0)$ porque **no** está definida en ese punto, y nos preguntamos si podemos extenderla con continuidad a una nueva función G como en el caso anterior.

En este caso, como vimos en un ejemplo anterior, no existe el límite en el origen. Por lo tanto no se puede definir una función G de manera de extender la continuidad de g a todo el plano.

Diferenciabilidad

Derivadas parciales

Consideremos una función $f(x, y)$ definida sobre $D \subset \mathbb{R}^2$.

Si fijamos una variable, por ejemplo a $y = b$, y permitimos que la otra varíe nuestra función f se convierte en una función de una sola variable y podemos trazar en $\mathbb{R}^3$ la curva $C1 : z = f(x, b)$ que corresponde a la gráfica de la función $F_1(x) = f(x, b)$ de la variable x

(De igual forma si fijamos $x = a$ y la función f queda $F_2(x) = f(a, y)$ siendo gráfica de la curva $C2 : z = f(a, y)$).

Si $F_1(x) = f(x, b)$ tiene derivada en a , entonces a esta derivada se la llama derivada parcial de f con respecto a x en (a, b) , y se denota como $\frac{\partial f(a, b)}{\partial x} = F_1'(a)$.

Recordando la definición de derivada de una función de una variable a través del límite del cociente incremental, tenemos:

$$\begin{aligned} \frac{\partial f(a, b)}{\partial x} &= F_1'(a) = \lim_{h \rightarrow 0} \frac{F_1(a + h) - F_1(a)}{h} \\ &= \lim_{h \rightarrow 0} \frac{f(a + h, b) - f(a, b)}{h} \end{aligned}$$

Definición 2.2. Si $f(x, y)$ es una función de dos variables, sus derivadas parciales respecto de x y de y son las funciones definidas por:

$$\frac{\partial f(x, y)}{\partial x} = \lim_{h \rightarrow 0} \frac{f(x + h, y) - f(x, y)}{h}$$

$$\frac{\partial f(x, y)}{\partial y} = \lim_{k \rightarrow 0} \frac{f(x, y + k) - f(x, y)}{k}$$

si los límites existen.

También usaremos la siguiente notación para las derivadas parciales:

$$f_x(x, y) = \frac{\partial f(x, y)}{\partial x}, \quad f_y(x, y) = \frac{\partial f(x, y)}{\partial y}.$$

A los fines prácticos para calcular las derivadas parciales es posible aplicar las reglas de derivación válidas para funciones de una variable (manteniendo a la otra fija, como si fuera una constante). Entonces, si las derivadas parciales son funciones continuas en $D \subset \mathbb{R}^2$, para obtener $f_x(x_0, y_0)$ y $f_y(x_0, y_0)$ se puede derivar por regla y luego evaluar las expresiones de f_x y f_y en el punto $(x_0, y_0) \in D$.

Diferenciabilidad para funciones de dos variables

La ecuación del plano tangente está dada por:

$$z = \frac{\partial f(a, b)}{\partial x} (x - a) + \frac{\partial f(a, b)}{\partial y} (y - b) + f(a, b)$$

Definición 2.6. Sea $f : D \subset \mathbb{R}^2 \rightarrow \mathbb{R}$ y sea $(x_0, y_0) \in D$. Se dice que f es **diferenciable** en $(x_0, y_0) \in D$ si:

$$\frac{f(x, y) - \left\{ \frac{\partial f(x_0, y_0)}{\partial x} (x - x_0) + \frac{\partial f(x_0, y_0)}{\partial y} (y - y_0) + f(x_0, y_0) \right\}}{\sqrt{(x - x_0)^2 + (y - y_0)^2}} \rightarrow 0$$

cuando (x, y) tiende (x_0, y_0)

Entonces, si se cumple ese límite, el plano tangente

$$\frac{\partial f(x_0, y_0)}{\partial x} (x - x_0) + \frac{\partial f(x_0, y_0)}{\partial y} (y - y_0) + f(x_0, y_0)$$

es una buena aproximación a la función $f(x, y)$ cuando (x, y) se acerca al punto (x_0, y_0) .

Una función f es diferenciable en (x_0, y_0) si la diferencia entre el valor real de la función y su aproximación lineal dada por el plano tangente, dividida por la distancia al punto (x_0, y_0) , tiende a cero cuando (x, y) se aproxima a (x_0, y_0) . Esto significa que el

error cometido al aproximar la función por su plano tangente es despreciable frente a la distancia al punto y , por lo tanto, la función se comporta localmente como una función lineal.

Proposición 2.8. *Si $f(x, y)$ es diferenciable en (x_0, y_0) , entonces f es continua en (x_0, y_0) .*


En general resulta más útil utilizar la contrarrecíproca de la afirmación anterior:

Si $f(x, y)$ NO es continua en (x_0, y_0) , entonces f NO es diferenciable en (x_0, y_0) .

Teorema 2.9. Condición suficiente para la diferenciabilidad

Sea $f : D \subset \mathbb{R}^2 \rightarrow \mathbb{R}$ y sea $(x_0, y_0) \in D$. Si existen las derivadas parciales $\frac{\partial f(x, y)}{\partial x}$ y $\frac{\partial f(x, y)}{\partial y}$, y además éstas son continuas en un entorno del punto (x_0, y_0) , entonces f es diferenciable en (x_0, y_0) .

¿Una función es diferenciable?



Propiedades

Propiedades 2.10. Dadas $f : D \subset \mathbb{R}^2 \rightarrow \mathbb{R}$ y $g : D \subset \mathbb{R}^2 \rightarrow \mathbb{R}$ funciones diferenciables en un entorno de $(x_0, y_0) \in D$ entonces en ese entorno vale que:

- $f + g$ es diferenciable
- $c.f$ es diferenciable
- $f.g$ es diferenciable
- f/g es diferenciable (suponemos que g nunca es 0 en D)

Plano tangente

Definición 2.12. Sea $f : D \subset \mathbb{R}^2 \rightarrow \mathbb{R}$ una función diferenciable en $(x_0, y_0) \in D$. Una ecuación del plano tangente a la gráfica de f en el punto $P_0 = (x_0, y_0, f(x_0, y_0))$ es :

$$\Pi_T : z = \frac{\partial f(x_0, y_0)}{\partial x} (x - x_0) + \frac{\partial f(x_0, y_0)}{\partial y} (y - y_0) + f(x_0, y_0)$$

Linealización

Se denomina linealización de f en el punto $P_0 = (x_0, y_0)$, o también polinomio de Taylor de primer orden alrededor de P_0 , a la siguiente función de dos variables:

$$L(x, y) = f(x_0, y_0) + \frac{\partial f(x_0, y_0)}{\partial x} (x - x_0) + \frac{\partial f(x_0, y_0)}{\partial y} (y - y_0)$$

cuya gráfica es el plano tangente Π_T a f en el punto P_0 .

De manera que si f es diferenciable en un punto P_0 de su dominio, entonces su gráfica admite un plano tangente en el punto ese punto, además este plano es localmente una “buena aproximación” a la gráfica de f cerca de P_0 , y por tanto podemos usar la función linealización para calcular la **aproximación lineal** de f en P_0 :

$$f(x, y) \approx L(x, y) = f(x_0, y_0) + \frac{\partial f(x_0, y_0)}{\partial x} (x - x_0) + \frac{\partial f(x_0, y_0)}{\partial y} (y - y_0)$$

Es decir, se puede obtener una aproximación lineal de f cerca de un punto si sabemos el plano tangente de f en ese punto y lo evaluamos para valores cercanos

Vector gradiente y derivada direccional

El vector gradiente de una función de dos variables es el vector cuyas componentes son las derivadas parciales de la función:

$$\nabla f(x, y) = \left(\frac{\partial f(x, y)}{\partial x}, \frac{\partial f(x, y)}{\partial y} \right) = (f_x(x, y), f_y(x, y))$$

Así como en una variable la derivada de una dada función representaba la dirección de crecimiento o decrecimiento, en varias variables es la derivada direccional en la dirección

de un vector dado la que representa la tasa de cambio de la función en la dirección de ese vector.

Definición 2.16. Sea $f : U \subset \mathbb{R}^2 \rightarrow \mathbb{R}$ la derivada direccional de f en $\mathbf{x}$ en la dirección del vector unitario $\vec{v} = (v_1, v_2)$ está dada por:

$$D_{\vec{v}}f(x, y) = \lim_{t \rightarrow 0} \frac{f((x, y) + t(v_1, v_2)) - f(x, y)}{t}$$

si es que el límite existe.

Teorema 2.17. Si $f : D \subset \mathbb{R}^2 \rightarrow \mathbb{R}$ es diferenciable, entonces existen todas las derivadas direccionales. La derivada direccional de f en $\mathbf{x}$ en la dirección de $\vec{v}$ está dada por:

$$Df(\mathbf{x}) = \nabla f(\mathbf{x}) \cdot \vec{v}$$

donde $\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right)$

Eso es el producto escalar: $(a, b) \cdot (c, d) = a \cdot c + b \cdot d$

Dirección de máximo crecimiento

Teorema 2.19. Si $f(x, y)$ es diferenciable en (a, b) la **dirección de máximo crecimiento** de f en (a, b) está dada por la dirección del gradiente de f en (a, b) .

Además, la máxima razón de cambio es $|\nabla f(a, b)|$

Extremos de funciones de dos variables

Definición 3.1. Sea $f : D \subset \mathbb{R}^2 \rightarrow \mathbb{R}$. Se dice que f tiene un **máximo local o relativo** en $(x_0, y_0) \in D$, si $f(x_0, y_0) \geq f(x, y)$ para todo punto (x, y) en algún disco centrado en (x_0, y_0) .

Si la desigualdad se verifica para todo punto del dominio de f , el máximo es **absoluto o global**.

Se dice que f tiene un **mínimo local o relativo** en $(x_0, y_0) \in D$ si $f(x_0, y_0) \leq f(x, y)$ para todo punto (x, y) en algún disco centrado en (x_0, y_0) .

Si la desigualdad se verifica para todo punto del dominio de f , el mínimo es **absoluto o global**.

Los máximos y mínimos locales constituyen los **extremos locales o relativos** de f .

Punto crítico

Definición 3.2. Sea $f : D \subset \mathbb{R}^2 \rightarrow \mathbb{R}$. Un punto (x_0, y_0) perteneciente al dominio de f es un **punto crítico** de f si se cumplen algunas de las siguientes condiciones:

- Las dos derivadas parciales primeras de f se anulan en (x_0, y_0)
- Al menos una de las derivadas parciales primeras de f **no** existe en (x_0, y_0)

En el primer caso (o sea, cuando el gradiente de f en el punto es el vector nulo), se dice que (x_0, y_0) es un **punto estacionario** de f .

Todo extremo local es un punto crítico, pero no todo punto crítico es un extremo local:

Teorema 3.3. Sea $f : D \subset \mathbb{R}^2 \rightarrow \mathbb{R}$, D un conjunto abierto.

Si f tiene un máximo o mínimo local en $(x_0, y_0) \in D$ y si existen las derivadas parciales primeras de f en dicho punto, entonces $f_x(x_0, y_0) = 0$ y $f_y(x_0, y_0) = 0$.

(Equivalentemente, $\nabla f(x_0, y_0) = 0$).

Teorema de Clairaut

Teorema 3.5. TEOREMA DE CLAIRAUT

Sea $f : D \rightarrow \mathbb{R}$ una función de dos variables definida en un conjunto abierto $D \subseteq \mathbb{R}^2$, si existen las segundas derivadas cruzadas y son continuas en D , entonces estas son iguales, es decir:

$$\frac{\partial^2 f}{\partial x \partial y} = \frac{\partial^2 f}{\partial y \partial x}$$

Criterio de las derivadas segundas

Teorema 3.6. CRITERIO DE LAS DERIVADAS SEGUNDAS

Sea $f : D \rightarrow \mathbb{R}$ una función de dos variables definida en un conjunto abierto $D \subseteq \mathbb{R}^2$ con segundas derivadas continuas en un entorno de un punto crítico (x_0, y_0) , llamemos

$$H = \frac{\partial^2 f}{\partial x \partial x}(x_0, y_0) \frac{\partial^2 f}{\partial y \partial y}(x_0, y_0) - \left(\frac{\partial^2 f}{\partial x \partial y}(x_0, y_0) \right)^2$$

entonces,

- Si $H > 0$ y $\frac{\partial^2 f}{\partial x \partial x}(x_0, y_0) > 0$ entonces $f(x, y)$ tiene un mínimo local en (x_0, y_0)
- Si $H > 0$ y $\frac{\partial^2 f}{\partial x \partial x}(x_0, y_0) < 0$ entonces $f(x, y)$ tiene un máximo local en (x_0, y_0) .
- Si $H < 0$ entonces $f(x, y)$ no tiene ni un máximo ni un mínimo en (x_0, y_0) .
Diremos que f tiene un **punto de ensilladura** (o **punto silla**) en (x_0, y_0) .
- Si $H = 0$ el criterio no decide.

(Obs: se puede usar $\frac{\partial^2 f}{\partial y \partial y}$ en lugar de $\frac{\partial^2 f}{\partial x \partial x}$)

Descenso del gradiente

Si bien es posible determinar los extremos de una función mediante métodos analíticos, como la búsqueda de puntos estacionarios y su categorización mediante el criterio de las derivadas segundas, existen algunas funciones que no resultan muy fáciles de estudiar. La optimización de funciones de una o múltiples variables, es decir, encontrar sus extremos, es una de las aplicaciones fundamentales del análisis matemático a lo largo de todas las ciencias.

En esta sección introduciremos un método numérico de optimización de funciones conocido como descenso del gradiente que nos permitirá minimizar una función $f(x)$ aproximando de forma iterativa lo mejor posible la solución analítica verdadera.

Los métodos de descenso, en general, utilizan la misma idea subyacente para conseguir una aproximación de la solución óptima: Partiendo de un punto inicial $x^{(0)}$, producir una secuencia de puntos $x^{(1)}, x^{(2)}, \dots, x^{(k)}$ tales que se minimice cada vez mas la función, es decir,

$$f(x^{(0)}) \geq f(x^{(1)}) \geq f(x^{(2)}) \geq \dots \geq f(x^{(k)})$$

Para construir dicha secuencia de puntos partiendo de uno inicial debemos decidir, en cierta forma, para dónde debemos trasladarnos. Podríamos movernos sobre una recta (en $\mathbb{R}^2$ cuando la función es de una variable) o sobre un plano (en $\mathbb{R}^3$ cuando la función es de dos variables).

Comencemos interpretando nuestro problema de forma simbólica: buscamos construir una secuencia de puntos $x^{(t+1)}$ que, tomando su anterior $x^{(t)}$, lo modifique de forma tal que en cada paso nos acerquemos un poco más a la solución mínima. Dicha modificación la realizaremos utilizando un vector, que funcionará como una brújula y se ajustará a cada paso para indicar nuestro camino hacia el “norte” (la solución óptima). Llamando Δx a dicho vector indicador, veamos que podemos expresar a cada nuevo punto como una actualización del anterior de la siguiente forma:

$$x^{(t+1)} = x^{(t)} + \eta \Delta x^{(t)} \quad (2)$$

Como sabemos, si sumamos un vector u a uno v , obtenemos otro vector s que tendrá la punta de v “trasladada” $|u|$ unidades en la dirección de u . Teniendo esto en cuenta, podemos ver que la ecuación (2) indica una traslación del punto $x^{(t)}$ en la dirección de nuestro vector “brújula” $\Delta x^{(t)}$. El factor η (eta) indica un escalamiento del vector de direccionamiento y lo llamaremos *tamaño de paso* (también conocido como *tasa de aprendizaje* en el contexto del Deep Learning). Veremos que este factor será necesario para conseguir una aproximación correcta a medida que nos acercamos a la solución verdadera. No siempre queremos que nuestro punto se actualice trasladándose la mismas unidades en cada paso, menos aun cuando nos estemos acercando al punto mínimo, donde buscaremos realizar modificaciones pequeñas, para asegurarnos precisión y no “pasarnos de largo”.

Luego, como el análisis nos ha enseñado, el vector gradiente nos indica la dirección de máximo o mínimo crecimiento de la función, y éste será nada más y nada menos que el vector “brújula” $\Delta x^{(t)}$. De esta forma, como $-\nabla f(\mathbf{x})$ indica la dirección de mínimo crecimiento de la función f en el punto $\mathbf{x}$, la ecuación (2) pasa a ser:

$$x^{(t+1)} = x^{(t)} - \eta \nabla f(x^{(t)}) \quad (3)$$

Tomando (3) , construiremos tantos puntos de forma tal que las actualizaciones cercanas a la solución verdadera sean cada vez menores. Pero... ¿cuántas debemos generar?

Notemos que cuando la función tome valores muy similares en dos aproximaciones consecutivas, como trataremos con funciones continuas, sería sensato pensar que la actualización fue muy pequeña y por ende nos encontramos cerca de la solución. Esta **condición de corte** tendrá la forma:

$$|f(x^{(k+1)}) - f(x^{(k)})| < \varepsilon$$

donde ε es un valor muy pequeño, en el orden de 10^{-5} o menor (cuanto menor mejor será la aproximación, pero mayor cantidad de iteraciones serán requeridas).

Algoritmo

1. Seleccionar un punto inicial x_0
2. Seleccionar el valor de tolerancia ε
3. Seleccionar el tamaño del paso η
4. Mientras no se cumpla la condición de corte: $|f(x^{(k+1)}) - f(x^{(k)})| < \varepsilon$
 - Calcular el siguiente punto de la secuencia según la función de actualización:

$$x^{(t+1)} = x^{(t)} - \eta \nabla f(x^{(t)})$$

Clase 2 - Regresión lineal

Regresión lineal simple

En términos de la matemática, cuando queremos comprender la relación entre variables del mundo real, solemos modelizarlo mediante una *función*. En este capítulo veremos la función más simple que existe entre dos variables x e y , la lineal.

Como sabemos, una **función lineal** tiene por gráfica a una recta y una ecuación de la siguiente forma:

$$y = \beta_0 + \beta_1 x$$

donde β_0 es la **ordenada al origen** y β_1 la **pendiente**.

Este tipo de relaciones son totalmente determinísticas ya que, para un valor fijo de la **variable independiente** x , se *determina* un *único* valor para la **variable dependiente** y . Pero en la amplia mayoría de los casos las relaciones que debemos modelizar no serán determinísticas, es decir, si conocemos el valor de x no sabremos *con exactitud* el de y . Esta última variable es lo que conocemos como *variable aleatoria*, a la cual nombraremos Y .

Lo visto en el ejemplo nos mostró que el valor esperado o medio de la variable Y es una función lineal de x :

$$E(Y|X = x) = \beta_0 + \beta_1 x$$

Pero para un valor fijo de x , Y *diffiere* de su valor esperado en una cantidad aleatoria. En otras palabras, la i -ésima observación y_i usualmente no será igual al valor esperado $E(Y|X = x_i)$. Para dar cuenta de esta diferencia entre el valor observado y el dato esperado, se creó una cantidad llamada **término de error aleatorio** o **desviación aleatoria** e_i . De esta forma conseguimos la denominada **ecuación de modelo**:

Definición 1.2. MODELO DE REGRESIÓN LINEAL SIMPLE

*Existen parámetros β_0 , β_1 y σ^2 de tal suerte que con cualquier valor fijo de la variable independiente x , la variable dependiente está relacionada con x por medio de la **ecuación de modelo***

$$Y = \beta_0 + \beta_1 x + e$$

La cantidad e en la ecuación de modelo es una variable aleatoria, que se supone está normalmente distribuida con $E(e) = 0$ y $V(e) = \sigma^2$

Notemos que sin la presencia del error e , cualquier par observado (x, y) correspondería a un punto que cae exactamente sobre la recta $y = \beta_0 + \beta_1 x$, llamada **línea de regresión verdadera**.

Al incluir el término de error aleatorio es posible encontrar puntos (x, y) por encima de la línea de regresión verdadera (cuando $e > 0$) o por debajo (cuando $e < 0$). Esta variación en el valor del error se le atribuye precisamente al parámetro σ^2 que suele ser mayor a 0 y representa la varianza de la variable aleatoria e .

Con respecto a los errores hacemos dos suposiciones importantes. Primero, asumimos que están normalmente distribuidos con $E(e_i) = 0$ y $V(e_i) = \sigma^2$, es decir, el valor esperado del error e_i será 0 y tendrá desviación estándar σ . La segunda suposición es que todos los errores son independientes, lo que significa que el valor del error para un caso observado no afecta en el valor de otro.




Figure 3: Puntos correspondientes a observaciones del modelo de regresión lineal

Entonces, teniendo en cuenta estas suposiciones y que el valor de la variable aleatoria Y está afectado por el del *error aleatorio* e , podemos decir que éste determina las propiedades de Y . Veamos que en general

$$Y = \beta_0 + \beta_1 x + e$$

Luego, para un valor fijo de x , Y es una variable aleatoria tal que:

$$E(Y|X = x) = E(\beta_0 + \beta_1 x + e) \stackrel{(1)}{=} \beta_0 + \beta_1 x + E(e) \stackrel{(2)}{=} \beta_0 + \beta_1 x$$

$$V(Y|X = x) = V(\beta_0 + \beta_1 x + e) \stackrel{(1)}{=} V(e) \stackrel{(3)}{=} \sigma^2$$

(1) Los términos β_0 y $\beta_1 x$ son constantes ya que el valor de x está fijo

(2) $E(e) = 0$

(3) $V(e) = \sigma^2$

Notemos que el *valor medio* de Y , en lugar de Y misma, es una función lineal de x . La línea de regresión verdadera $y = \beta_0 + \beta_1 x$ es por consiguiente la **línea de valores medios**. La pendiente β_1 de la línea de regresión verdadera se interpreta como el cambio esperado de Y cuando el valor de x incrementa en una unidad. La segunda relación manifiesta que la cantidad de variabilidad en la distribución de valores Y es la misma con cada valor diferente de x , es decir, se mantiene constante (homogeneidad de varianza).




Figure 4: Distribución de Y con diferentes valores de x

Por último, con x fija, como Y es la suma de una constante $\beta_0 + \beta_1 x$ y una variable aleatoria normalmente distribuida e , Y “hereda” esta distribución. Además, debido a la independencia entre los valores de e_i , los datos observados y_i también serán independientes.

Método de mínimos cuadrados

¿De dónde sacamos β_0 y β_1 ?

¿Cuáles son sus valores?

Tal es así que el método de mínimos cuadrados determina que la recta de mejor ajuste es aquella tal que las distancias verticales de los puntos observados hasta la recta sean las mínimas posibles. La medida que tomará el método es la suma de los cuadrados de estas desviaciones

Definición 1.3. MÉTODO DE MÍNIMOS CUADRADOS

La desviación vertical del punto (x_i, y_i) con respecto a la línea $y = \beta_0 + \beta_1 x$ es

$$\text{la altura del punto} - \text{altura de la línea} = y_i - (\beta_0 + \beta_1 x)$$

La suma de las desviaciones verticales al cuadrado de los puntos $(x_1, y_1), \dots, (x_n, y_n)$ a la línea es entonces

$$f(b_0, b_1) = \sum_{i=1}^n [y_i - (b_0 + b_1 x_i)]^2$$

Las estimaciones puntuales de β_0 y β_1 , denotadas por $\hat{\beta}_0$ y $\hat{\beta}_1$ llamadas **estimaciones de mínimos cuadrados**, son aquellos valores que reducen al mínimo a $f(b_0, b_1)$. Es decir, $\hat{\beta}_0$ y $\hat{\beta}_1$ son tales que

$$f(\hat{\beta}_0, \hat{\beta}_1) \leq f(b_0, b_1) \quad \forall b_0, b_1$$

La **línea de regresión estimada** o **línea de mínimos cuadrados** es entonces la línea cuya ecuación es

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$




Figure 6: Desviaciones verticales de los puntos observados con respecto a las rectas

Luego, el método de mínimos cuadrados toma cada una de dichas desviaciones, las eleva al cuadrado y las suma. Aquella recta que minimice la suma será la que se considerará la recta de ajuste.

Lo que se debe hacer es minimizar $f(b_0, b_1)$, y para eso, se usarán los conceptos de derivaciones parciales de la clase 1. Luego del proceso nos quedan las siguientes ecuaciones normales:

$$nb_0 + b_1 \left(\sum_{i=1}^n x_i \right) = \sum_{i=1}^n y_i$$

$$b_0 \left(\sum_{i=1}^n x_i \right) + b_1 \left(\sum_{i=1}^n x_i^2 \right) = \sum_{i=1}^n x_i y_i$$

La estimación de mínimos cuadrados de la pendiente β_1 de la recta de regresión verdadera será entonces

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

Otra forma de expresar a S_{xy} y S_{xx} es:

$$S_{xy} = \sum_{i=1}^n x_i y_i - \frac{\sum x_i \sum y_i}{n} \quad S_{xx} = \sum_{i=1}^n x_i^2 - \frac{(\sum x_i)^2}{n}$$

La estimación de mínimos cuadrados de la ordenada al origen β_0 es:

$$\hat{\beta}_0 = \frac{\sum y_i - \hat{\beta}_1 \sum x_i}{n} = \bar{y} - \hat{\beta}_1 \bar{x}$$

Recta de regresión estimada

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Estimación de σ^2

El parámetro σ^2 determina la cantidad de variabilidad en el modelo de regresión. Un valor grande de σ^2 conducirá a (x_i, y_i) observados que están bastante dispersos en torno a la línea de regresión verdadera, mientras que σ^2 sea pequeña los puntos observados tenderán a quedar cerca de la línea verdadera.

Este parámetro podrá ser estimado una vez que hayamos calculado el modelo de regresión lineal, es decir la recta de la forma $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$. Si reemplazamos sucesivamente los valores x_i en la ecuación, obtendremos los denominados **valores ajustados** $\hat{y}_1, \hat{y}_2, \dots, \hat{y}_n$.

Definición 1.4. Las desviaciones verticales entre los valores observados y valores ajustados

$$\hat{e}_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i) \quad i = 1, \dots, n$$

recibirán el nombre de **residuos**

Los residuos son cantidades que determinan directamente la variabilidad del modelo. Notemos que representan los errores que se generan al ajustar una recta a puntos que no siguen una relación totalmente determinística.

Teniendo esto en consideración, definiremos la estimación de la variabilidad σ^2 de la siguiente forma:

Definición 1.5. La suma de cuadrados de error o residuales denotada por *SCE*, es

$$SCE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n [y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)]^2$$

Luego, el estimador insesgado de σ^2 es

$$\hat{\sigma}^2 = \frac{SCE}{n - 2}$$

Observemos que para calcular la suma de cuadrados residuales debemos realizar operaciones aritméticas tediosas y evaluar la ecuación de la recta para cada valor de x_i , por lo que a continuación presentamos una forma alternativa para dicha cantidad:

$$SCE = S_{yy} - \frac{(S_{xy})^2}{S_{xx}}$$

donde

$$S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2$$

Coeficiente de determinación

En esta sección presentaremos una métrica con la que podremos medir cuán bueno fue el trabajo realizado por nuestro modelo de regresión lineal, es decir, nos indicará cuán bien se ajustó la recta a los datos observados.

Como ya sabemos, la varianza de una variable aleatoria nos determina el grado de dispersión de los valores con respecto a su media o valor esperado.




Figure 7: Desviaciones verticales de los puntos observados con respecto a la media muestral

Si tomamos cada uno de los desvios de esta figura, los elevamos al cuadrado y los sumamos obtenemos la denominada **suma total de cuadrados**. Simbólicamente

$$\sum_{i=1}^{30} (y_i - \bar{y})^2$$

Eso es lo mismo que S_{yy} que describe la variabilidad total observada (ignorando a la variable pronosticadora x) de la variable y .

Cuando agregamos la variable independiente x podemos obtener la suma de los errores al cuadrado SCE que describe la variabilidad no explicada por el modelo de regresión.

Explicación de un modelo

La explicación dada por un modelo lineal de la variación de una variable puede ser interpretada con la siguiente pregunta: “Si trazo las desviaciones de los puntos observados a la recta horizontal de la media y luego reemplazo dichos puntos por la recta de ajuste y vuelvo a trazar las desviaciones, ¿estas últimas desviaciones se parecen a las primeras?”. Si lo hacen, decimos que el modelo explica gran parte o la totalidad de la variación de la variable. En caso contrario el modelo no explica la variabilidad. Por ejemplo, la siguiente es una figura con un modelo que explica la totalidad de la variación de y :





Figure 8: Modelo que explica la totalidad de la variación.



Una vez comprendida esta idea de explicación de la variabilidad, podemos proceder a construir una métrica que mida la calidad del ajuste que obtenemos con el método de mínimos cuadrados. Tomaremos las siguientes 3 cantidades:

- Suma total de cuadrados

$$STC = S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2$$

- Suma de cuadrados de error

$$SCE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Suma de cuadrados debido a la regresión

$$SCR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

La variación total de la variable y denotada por STC podemos escribirla como la suma de la variabilidad **explicada** SCR y la **no explicada** SCE . Luego

$$STC = SCR + SCE$$

Si movemos un poco los términos podemos obtener

$$SCR = STC - SCE$$

Finalmente, dividiendo a ambos miembros por la variabilidad total (STC) obtenemos la proporción o porcentaje de explicación de la variación por parte del modelo:

$$\frac{SCR}{STC} = 1 - \frac{SCE}{STC}$$

Definición 1.6. El *coeficiente de determinación*, denotado por R^2 , está dado por

$$R^2 = 1 - \frac{SCE}{STC}$$

Se interpreta como la proporción de variación *y* observada que puede ser explicada por el modelo de regresión lineal simple (atribuida a una relación lineal aproximada entre *y* y *x*).

Debemos destacar que la suma de desviaciones al cuadrado con respecto a la línea de mínimos cuadrados (*SCE*) es más pequeña que la suma de desviaciones al cuadrado con respecto a *cualquier* otra línea. Esto se debe a que dicha suma se minimizó mediante el método de mínimos cuadrados. De esta forma, siempre $SCE < STC$ a menos que la recta de mínimos cuadrados sea la propia recta horizontal de la media, en cuyo caso $SCE = STC$.

La razón (SCE/STC) representa la proporción de variabilidad total que no puede ser explicada por el modelo de regresión lineal, siendo un valor entre 0 y 1. Luego $1 - (SCE/STC)$ también será un número entre 0 y 1.

Mientras más alto es el valor de R^2 , mejor será nuestro modelo de regresión lineal simple al explicar la variación de *y*.

Coeficiente de correlación lineal

El coeficiente de correlación es la medida que podemos usar para describir qué tan fuerte es la relación lineal entre dos variables *x* e *y*. Su cálculo se puede realizar mediante la aplicación de diferentes fórmulas, obteniéndose exactamente el mismo resultado. Siendo:

$$r = \frac{Cov(x, y)}{\sqrt{S_{xx}S_{yy}}} \quad r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} \quad r = \sqrt{R^2}$$

Cuando la pendiente de la ecuación de estimación β_1 es positiva, *r* es la raíz cuadrada positiva, pero si β_1 es negativa, *r* toma el valor negativo de la raíz. De esta forma, podemos identificar que **el signo de *r* indica la dirección de la relación entre las dos variables *x* e *y***. Si existe una relación inversa (esto es, si *y* disminuye al aumentar *x*), entonces *r* tomará valores entre 0 y -1 y, de manera similar, si existe una relación directa (si *y* aumenta al aumentar

x), entonces r obtendrá un valor en el intervalo de 0 a 1. En la siguiente figura se ilustra estas características de la correlación lineal r :




Figure 10: Interpretación gráfica de los distintos valores del coeficiente de correlación lineal

Propiedades de los estimadores

- Tanto $\hat{\beta}_0$ como $\hat{\beta}_1$ son estimadores *insesgados*, es decir:

$$E(\hat{\beta}_0) = \beta_0 \quad E(\hat{\beta}_1) = \beta_1$$

- Las varianzas de los estimadores son de la forma

$$V(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}} \quad V(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)$$

- Tanto $\hat{\beta}_0$ como $\hat{\beta}_1$ están normalmente distribuidas con las varianzas y valores medios mencionados en los puntos anteriores.

Inferencias estadísticas

Sobre β_1

Teorema 1.7. *La suposición del modelo de regresión lineal simple implica que la variable estándar (o estadístico)*

$$T = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

tiene una distribución t Student con $n - 2$ grados de libertad.

Intervalo de confianza

Definición 1.8. *Un intervalo de confianza de $100(1 - \alpha)\%$ para la pendiente β_1 de la línea de regresión verdadera es:*

$$\left[\hat{\beta}_1 - t_{\frac{\alpha}{2}, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} ; \hat{\beta}_1 + t_{\frac{\alpha}{2}, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \right]$$

Este intervalo tiene la misma forma que muchos de los vistos en Matemática 3. Está centrado en la estimación puntual del parámetro y el ancho depende del nivel de confianza deseado y de la cantidad de variabilidad del estimador $\hat{\beta}_1$

Test de hipótesis

Como se vio en los preliminares, todo test o prueba de hipótesis comienza fijando la *hipótesis nula*, que representa aquella aseveración que “favoreceremos” hasta que se demuestre que la hipótesis alternativa es la correcta.

En este caso deseamos probar la hipótesis de que la pendiente β_1 es igual a una constante, por ejemplo θ . Entonces supongamos las hipótesis:

$$H_0 : \beta_1 = \theta \qquad H_a : \beta_1 \neq \theta$$

Luego, el siguiente paso en una prueba es la elección del estadístico de prueba. Utilizaremos uno similar al presentado en el Teorema 1.7:

$$T = \frac{\hat{\beta}_1 - \theta}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

El cual, bajo la hipótesis nula $\beta_1 = \theta$ tiene distribución student con $n - 2$ grados de libertad.

Por último hay que fijar la regla de decisión:

$$\text{Regla : } \begin{cases} \text{rechazar } H_0 & \text{si } |T| > t_{\frac{\alpha}{2}, n-2} \\ \text{aceptar } H_0 & \text{si } |T| \leq t_{\frac{\alpha}{2}, n-2} \end{cases}$$

- Si $H_a : \beta_1 > \theta$ se rechaza $H_0 : \beta_0 = \theta$ si $T > t_{\alpha, n-2}$
- Si $H_a : \beta_1 < \theta$ se rechaza $H_0 : \beta_0 = \theta$ si $T < -t_{\alpha, n-2}$

Destaquemos el caso especial cuando tomamos $H_0 : \beta_1 = 0$ contra $H_a : \beta_1 \neq 0$ ¿Qué significa esto en nuestro modelo de regresión lineal?

Notemos que aceptar $H_0 : \beta_1 = 0$ implica aceptar que la pendiente de la recta de regresión verdadera es nula, lo que es equivalent a concluir que no existe ninguna relación lineal entre las variables x e Y . Por otro lado, si se rechaza esta hipótesis nula, significaría que x tiene cierta importancia al explicar la variabilidad de Y . También puede indicar que le modelo lineal es adecuado, o que, aunque exista efecto lineal, pueden obtenerse mejores resultados agregando términos polinomiales de mayor grado en x .

Sobre β_0

Intervalo de confianza

Intervalos de confianza de nivel $(1 - \alpha)$ se deducen de manera análoga a lo visto para β_1 .

En este caso utilizamos el estadístico

$$T = \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}}$$

El cual tiene distribución student con $n - 2$ grados de libertad. Luego, el intervalo es:

$$\left[\hat{\beta}_0 - t_{\frac{\alpha}{2}, n-2} \sqrt{\sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} ; \hat{\beta}_0 + t_{\frac{\alpha}{2}, n-2} \sqrt{\sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} \right]$$

Test de hipótesis

De manera similar a lo visto sobre β_1 , se puede realizar tests de hipótesis sobre β_0 . Específicamente si tenemos las hipótesis

$$H_0 : \beta_0 = \gamma \qquad H_a : \beta_0 \neq \gamma$$

y el estadístico de prueba es

$$T = \frac{\hat{\beta}_0 - \gamma}{\sqrt{\sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}}$$

que bajo $H_0 : \beta_0 = \gamma$ tiene distribución student con $n - 2$ grados de libertad. Finalmente, la regla de decisión de la prueba es igual a la de β_1 :

$$\text{Regla : } \begin{cases} \text{rechazar } H_0 & \text{si } |T| > t_{\frac{\alpha}{2}, n-2} \\ \text{aceptar } H_0 & \text{si } |T| \leq t_{\frac{\alpha}{2}, n-2} \end{cases}$$

- Si $H_a : \beta_0 > \gamma$ se rechaza $H_0 : \beta_0 = \gamma$ si $T > t_{\alpha, n-2}$
- Si $H_a : \beta_0 < \gamma$ se rechaza $H_0 : \beta_0 = \gamma$ si $T < -t_{\alpha, n-2}$

Intervalo de confianza para la respuesta media

Así como vimos en el inicio de la Sección 1.2, dado un punto, el valor esperado de la variable aleatoria Y_i para un valor fijo de x era:

$$E(Y_i|X = x_i) = \beta_0 + \beta_1 x_i$$

Luego, si utilizamos el método de mínimos cuadrados para hallar $\hat{\beta}_1$ y $\hat{\beta}_0$ y fijamos un valor de x , x^* , entonces $\hat{\beta}_0 + \hat{\beta}_1 x^*$ puede ser considerada como una estimación puntual del valor medio de Y o una predicción del valor Y (cuando $x = x^*$)

Como $\hat{\beta}_1$ y $\hat{\beta}_0$ varían según la muestra aleatoria utilizada (son estadísticos, es decir, variables aleatorias), luego se desprende que $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x^*$ cambia de valor de muestra en muestra para un mismo x^* fijo, por lo que también es un estadístico.

Del mismo modo que los intervalos de confianza para β_1 y β_0 estaban basados en propiedades de la distribución de muestreo de β_1 y β_0 , un intervalo de confianza para un valor y medio en regresión está basado en propiedades de la distribución de muestreo del estadístico $\hat{\beta}_0 + \hat{\beta}_1 x^*$.

Sea $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x^*$, donde x^* es un valor fijo de x . Entonces

- La esperanza de $\hat{Y}$ es

$$E(\hat{Y}) = E(\hat{\beta}_0 + \hat{\beta}_1 x^*) = \beta_0 + \beta_1 x^*$$

De forma tal que $\hat{\beta}_0 + \hat{\beta}_1 x^*$ es un estimador puntual insesgado de $\beta_0 + \beta_1 x^*$.

- La varianza de $\hat{Y}$ es

$$\hat{Y} = V(\hat{\beta}_0 + \hat{\beta}_1 x^*) = \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)$$

y la desviación estandar es la raíz cuadrada de esta expresión.

- $\hat{Y}$ tiene distribución normal con esperanza y varianza anteriores.

Teorema 1.9. *La variable aleatoria*

$$T = \frac{\hat{\beta}_0 + \hat{\beta}_1 x^* - (\beta_0 + \beta_1 x^*)}{\sqrt{\sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}}$$

tiene distribución student con $n - 2$ grados de libertad.

Definición 1.10. *Un **intervalo de confianza** de $100(1 - \alpha)\%$ **para** $\beta_0 + \beta_1 x^*$ de la línea de regresión verdadera es:*

$$\left[\hat{\beta}_0 + \hat{\beta}_1 x^* - t_{\frac{\alpha}{2}, n-2} \sqrt{\sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)} ; \hat{\beta}_0 + \hat{\beta}_1 x^* + t_{\frac{\alpha}{2}, n-2} \sqrt{\sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)} \right]$$

Observaciones:

- Notar que el ancho del intervalo de confianza depende de x^* . El ancho será mínimo cuando $x^* = \bar{x}$ y crece a medida que $|x^* - \bar{x}|$ aumenta.
- Al repetir los cálculos anteriores para varios valores diferentes de x^* pueden obtenerse intervalos de confianza para cada valor correspondiente de $\beta_0 + \beta_1 x^*$

Intervalo de predicción para valores futuros de Y

Como hemos visto, un intervalo de confianza incluye los valores posibles de un *parámetro* de la población, cuyo valor es fijo pero desconocido. En cambio, un valor futuro de Y no es un parámetro sino una variable aleatoria. Es por esto que se hace referencia a un intervalo de valores factibles para un valor de Y como un **intervalo de predicción** en lugar de intervalo de confianza.

Notemos que el *error de estimación* de Y es $(\beta_0 + \beta_1 x^*) - (\hat{\beta}_0 + \hat{\beta}_1 x^*)$, una diferencia entre una cantidad fija (pero desconocida) y una variable aleatoria.

Por otro lado, el *error de predicción* es $Y - (\hat{\beta}_0 + \hat{\beta}_1 x^*)$, que resulta ser una diferencia entre dos variables aleatorias. Existe por lo tanto más incertidumbre en la predicción que en la estimación, de forma tal que un intervalo de predicción será más ancho que uno de confianza.

Ahora, como hemos visto, $E(Y^*) = \beta_0 + \beta_1 x^*$ y $E(\hat{Y}^*) = E(\hat{\beta}_0 + \hat{\beta}_1 x^*) = \beta_0 + \beta_1 x^*$, por lo tanto

$$E(Y^* - \hat{Y}^*) = 0$$

Es decir, el error esperado en la predicción de Y es 0. Por otro lado

$$V(Y^* - \hat{Y}^*) = \sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)$$

$Y^* - \hat{Y}^*$ tiene distribución normal con varianza y esperanza anteriores.

Teorema 1.11. *La variable aleatoria*

$$T = \frac{Y^* - \hat{Y}^*}{\sqrt{\sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}}$$

tiene distribución student con $n - 2$ grados de libertad.

Por el argumento usual llegamos a:

Definición 1.12. *Un intervalo de predicción del $100(1 - \alpha)\%$ para Y^* es:*

$$\left[\hat{Y}^* - t_{\frac{\alpha}{2}, n-2} \sqrt{\sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)} ; \hat{Y}^* + t_{\frac{\alpha}{2}, n-2} \sqrt{\sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)} \right]$$

La interpretación del nivel de predicción $100(1 - \alpha)\%$ es idéntica al de los niveles de confianza. Si se utiliza repetidamente, a la larga los intervalos resultantes en realidad contendrán los valores y observados el $100(1 - \alpha)\%$ del tiempo.

Regresión lineal múltiple

Definición 2.1. MODELO DE REGRESIÓN LINEAL MÚLTIPLE

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon$$

Los coeficientes $\beta_0, \dots, \beta_k$ se estimarán de manera similar que la regresión lineal simple, por el método de mínimos cuadrados buscando minimizar una función de error:

$$f(b_0, b_1, \dots, b_k) = \sum_{i=1}^n [y_i - (b_0 + b_1 x_{1i} + b_2 x_{2i} + \cdots + b_k x_{ki})]^2$$

Para hallar las estimaciones de mínimos cuadrados, es decir, los valores b_i que hacen mínima a la función $f(b_0, b_1, \dots, b_k)$, debemos calcular las derivadas parciales de f con respecto a cada variable b_i . Realizando el cálculo de estas derivadas, obtenemos:

$$\begin{aligned}
\frac{\partial f}{\partial b_0} &= -2 \sum_{i=1}^n y_i - (b_0 + b_1 x_{1i} + b_2 x_{2i} + \cdots + b_k x_{ki}) \\
\frac{\partial f}{\partial b_1} &= -2 \sum_{i=1}^n x_{1i} \cdot [y_i - (b_0 + b_1 x_{1i} + b_2 x_{2i} + \cdots + b_k x_{ki})] \\
&\vdots \\
\frac{\partial f}{\partial b_k} &= -2 \sum_{i=1}^n x_{ki} \cdot [y_i - (b_0 + b_1 x_{1i} + b_2 x_{2i} + \cdots + b_k x_{ki})]
\end{aligned}$$

Igualando cada una de ellas a 0 (para obtener el punto estacionario de la función), obtenemos el siguiente sistema de **ecuaciones normales**:

$$\begin{aligned}
\sum y_i &= nb_0 + b_1 \sum x_{1i} + b_2 \sum x_{2i} + \cdots + b_k \sum x_{ki} \\
\sum x_{1i} y_i &= b_0 \sum x_{1i} + b_1 \sum x_{1i}^2 + b_2 \sum x_{1i} x_{2i} + \cdots + b_k \sum x_{1i} x_{ki} \\
\sum x_{2i} y_i &= b_0 \sum x_{2i} + b_1 \sum x_{2i} x_{1i} + b_2 \sum x_{2i}^2 + \cdots + b_k \sum x_{2i} x_{ki}
\end{aligned}$$

$\vdots$

$$\sum x_{ki} y_i = b_0 \sum x_{ki} + b_1 \sum x_{ki} x_{1i} + b_2 \sum x_{ki} x_{2i} + \cdots + b_k \sum x_{ki}^2$$

El sistema de ecuaciones anterior puede disponerse en forma matricial de la siguiente manera:

$$\underbrace{\begin{pmatrix} n & \sum x_{1i} & \sum x_{2i} & \cdots & \sum x_{ki} \\ \sum x_{1i} & \sum (x_{1i})^2 & \sum x_{1i}x_{2i} & \cdots & \sum x_{1i}x_{ki} \\ \sum x_{2i} & \sum x_{2i}x_{1i} & \sum (x_{2i})^2 & \cdots & \sum x_{2i}x_{ki} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_{ki} & \sum x_{ki}x_{1i} & \sum x_{ki}x_{2i} & \cdots & \sum (x_{ki})^2 \end{pmatrix}}_X \cdot \underbrace{\begin{pmatrix} b_0 \\ b_1 \\ b_2 \\ \vdots \\ b_k \end{pmatrix}}_{\beta} = \underbrace{\begin{pmatrix} \sum y_i \\ \sum x_{1i} y_i \\ \sum x_{2i} y_i \\ \vdots \\ \sum x_{ki} y_i \end{pmatrix}}_Y$$

Entonces tenemos el siguiente sistema matricial escrito de la forma:

$$Y = X \beta$$

Si nuestra matriz X fuera cuadrada fácilmente quedaría $\beta = X^{-1}Y$, pero en general esto no sucede, luego la forma tradicional de solucionarlo es multiplicando ambos lados de la ecuación por la traspuesta de la matriz X para conseguir un sistema cuadrado y resolverlo usando la inversa (de la nueva matriz).

$$X^T Y = X^T X \beta$$

Recordar que, al igual que en regresión simple, los valores $b_0, \dots, b_k$ que minimicen la función son estimaciones de los estimadores puntuales $\beta_0, \dots, \beta_k$, por lo que los denotamos con $\hat{\beta}_0, \dots, \hat{\beta}_k$. Luego, la solución del sistema para encontrar los estimadores de los coeficiente será:

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

Finalmente la estimación queda de la forma:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_k x_k$$

Varianza y coeficiente de determinación

Si bien la forma de la estimación de la varianza del modelo y el coeficiente de determinación son similares a aquellas que se utilizan para la regresión lineal simple, sufren algunas modificaciones en el caso de la regresión múltiple.

En primer lugar recordemos que con el modelo de regresión que contruyamos podemos realizar estimaciones llamadas *valores pronosticados* o *ajustados* $\hat{y}_0, \hat{y}_1, \dots, \hat{y}_n$. Luego, las diferencias entre los valores pronosticados y los observados $y_0 - \hat{y}_0, y_1 - \hat{y}_1, \dots, y_n - \hat{y}_n$ son los *residuos* del modelo y nos aportan una noción de cuán bueno es nuestro ajuste. Cuanto más cerca de 0 se encuentren los residuos, mejor será el trabajo que haga la ecuación estimada para predecir los valores y .

La *estimación de la varianza del modelo* σ^2 está basada en la suma de residuos al cuadrado:

$$SS_r = SCE = \sum (y_i - \hat{y}_i)^2 = \sum [y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_k x_k)]^2$$

y se define de la forma

Definición 2.2. ESTIMACIÓN DE LA VARIANZA

$$\sigma^2 = \frac{SSr}{n - k - 1} = \frac{\sum (y_i - \hat{y}_i)^2}{n - k - 1}$$

Por otro lado, considerando al *coeficiente de determinación* R^2 , la forma de calcularlo es idéntica a como lo hacemos para el modelo de regresión simple:

$$R^2 = 1 - \frac{SS_r}{STC} = 1 - \frac{SCE}{STC}$$

Teniendo esto en cuenta, debemos destacar que muchos analistas prefieren ajustar el coeficiente de determinación al número de variables independientes k , con la intención de evitar sobreestimar el efecto que tiene agregar una variable independiente sobre la cantidad de variabilidad explicada por la ecuación de regresión estimada. El coeficiente de determinación ajustado se calcula como sigue:

Definición 2.3. COEFICIENTE DE DETERMINACIÓN AJUSTADO

$$R_a^2 = 1 - (1 - R^2) \left(\frac{n - k}{n - k - 1} \right)$$

Finalmente, la raíz cuadrada del *coeficiente de determinación múltiple* se denomina coeficiente de correlación múltiple r :

$$r = \sqrt{R_a^2}$$

Clase 3 - Teoría de números

Ley de monotonía de la suma y producto en enteros

Ley de Monotonía de la suma: Dados tres números enteros a , b y c , vale que si $a \leq b$ entonces $a + c \leq b + c$.

Ley de Monotonía del producto: Dados números enteros a , b , vale que si $a \leq b$ entonces $a \cdot c \leq b \cdot c$ si c es positivo y $a \cdot c \geq b \cdot c$ si c es un número negativo .

Divisibilidad en enteros

Está parcialmente definida o no está cerrada en los enteros ($\frac{2}{3}$ no es entero)

Definición 1.1. *Dados dos números enteros a y b , con b no nulo. Se dice que b **divide** a a , y se escribe $b|a$, si existe un entero c tal que*

$$a = b \cdot c$$

En este caso se dice que b es un divisor de a , a es divisible por b ó que a es múltiplo de b

Por ejemplo: 2 divide a 4 porque $4 = 2 \cdot 2$

Propiedades

- $a|a$
- $1|a$
- $a|0$
- $a|b$ entonces $a|-b$, $-a|b$ y $-a|-b$
- $a|b$ entonces $a|bc$
- $a|b$ y $b|c$ entonces $a|c$

- $a|b$ y $a|c$ entonces $a|b+c$

Algoritmo de división

Dados $a, b \in \mathbb{Z}$ con $b \neq 0$, cuando no existe el entero c que haga valer la igualdad $a = bc$, se trata de realizar la división *inexacta* entre a y b .

Es decir que se trata de aproximar *de la mejor manera posible* a a por un múltiplo de b . La diferencia entre a y dicho número es lo que llamamos *resto* de la división; que será nulo en el caso que a sea múltiplo de b .

Teorema 1.2. *Dados $a, b \in \mathbb{Z}$ con $b \neq 0$, existen y son únicos c (cociente) y r (resto) enteros tales que*

$$a = bc + r \quad \text{con} \quad 0 \leq r < |b|$$

Cambio de base

Teorema 1.5. *Sea b un entero mayor a 1. Entonces para todo entero positivo a , existe un entero no negativo k , y enteros $0 \leq a_j < b$ con $j = 1, 2, \dots, k$ tales que $a = a_k b^k + a_{k-1} b^{k-1} + a_{k-2} b^{k-2} + \dots + a_1 b + a_0$ con $a_k \neq 0$. Además esta representación es única.*

En la expresión $a = a_k b^k + a_{k-1} b^{k-1} + a_{k-2} b^{k-2} + \dots + a_1 b + a_0$, $0 \leq a_j < b$ con $j = 1, 2, \dots, k$, el número b es llamado **base** de la representación. Si la base no se especifica se sobreentiende que es igual a 10

Se acostumbra a escribir $a = (a_k a_{k-1} a_{k-2} \dots + a_1 a_0)_b$

Ejemplo 1.6. *Escribir 37 en base 5.*

- $37 = 5 \cdot 7 + 2$

- $7 = 5 \cdot 1 + 2,$

- $1 = 5 \cdot 0 + 1$

Luego, $37 = (122)_5$

Enteros primos

Definición 1.7. *Un número entero $p \neq 1$ se dice **primo** si sus únicos divisores son los triviales (ésto es el propio número, su opuesto, 1 y -1). Caso contrario se dice que el número es **compuesto***

Hay infinitos números primos

Si m es un entero compuesto, entonces existe un primo p tal que p divide a m

Criba de eratóstenes

La Criba de Eratóstenes es un método algorítmico para encontrar y /o enumerar los primos (positivos) menores que un natural fijo dado.

Partimos de una lista de números que van de 2 hasta el número dado y vamos eliminando los números compuestos (los múltiplos de los primos).

Eliminamos de la lista los múltiplos de 2.

Luego tomamos el primer número después del 2 que no fue eliminado (el 3) y eliminamos de la lista sus múltiplos, y así sucesivamente.

El proceso termina cuando el cuadrado del mayor número primo (uno que ya sabemos que es primo o confirmamos que es primo) es menor que el número natural que teníamos fijo (el del final de la lista).

Los números que no fueron eliminados y permanecen en la lista son los primos.

Teorema fundamental de la aritmética

Teorema 1.8. TEOREMA FUNDAMENTAL DE LA ARITMÉTICA

Todo número entero distinto de $0, 1, -1$ es producto finito de números primos y esa factorización es única salvo el orden.

Máximo común divisor (MCD)

Teorema 1.9. MÁXIMO COMÚN DIVISOR

Dados $a, b \in \mathbb{Z}$ no simultáneamente nulos, existe un único entero $d > 0$ que satisface:

- $d|a$ y $d|b$
- Si existe D tal que $D|a$ y $D|b$ entonces $D|d$

*Este entero d es el denominado **máximo común divisor entre a y b** y se lo denota (a, b) ó $m.c.d(a, b)$*

Algoritmo de euclides

El algoritmo de Euclides es un método antiguo y eficiente para calcular el mcd . Fue originalmente descrito por Euclides en su obra Elementos. El algoritmo extendido es una ligera modificación que permite expresar al mcd como una combinación lineal.

Dados $a, b \in \mathbb{Z}$, supongamos $a \geq b$ con $b \neq 0$.

Por el algoritmo de la división existen c_1 y r_1 tales que $a = c_1b + r_1$ con $0 \leq r_1 < b$.

Si $r_1 = 0$, $(a, b) = (b, r_1) = (b, 0) = b$

Si $r_1 \neq 0$, podemos decir que existen c_2 y r_2 tales que $b = c_2r_1 + r_2$ con $0 \leq r_2 < r_1$. Si r_2 es cero, ya está, el mcd es r_1 , si no es cero repetimos el proceso. Y así sucesivamente.

Concluimos: $(a, b) = (b, r_1) = (r_1, r_2) = (r_2, r_3) = \dots = (r_{n-1}, r_n) = (r_n, 0) = r_n$ siendo r_n el último resto no nulo

Ejemplos 1.12. • $(60, 45) = (45, 15) = (15, 0) = 15$

• $(86, 22) = (22, 20) = (20, 2) = (2, 0) = 2$

Identidad de Bézout

Proposición 1.13. *Dados $a, b \in \mathbb{Z}$ y d su m.c.d, existen enteros m y n tales que*

$$d = ma + nb$$

Coprimos

Definición 1.16. *Si $(a, b) = 1$ se dice que a y b son **coprimos***

Proposición 1.19. *Sea d el máximo común divisor entre los enteros a y b , entonces existen A y B números enteros tales que $a = d.A$ y $b = d.B$ y $(A, B) = 1$*

Demostración: Queremos probar que A y B son coprimos. Supongamos que no lo son, es decir, existe $D = (A, B)$

D divide a A , entonces existe un entero k tal que $A = Dk$, luego $a = d.A = d.Dk$ y por lo tanto $dD|a$.

De la misma forma podemos ver que dD divide a b .

De esta forma probamos que dD divide a a y b , entonces dD divide al (a, b) , $dD|d$ (por definición de mcd), pero esto es una (ya que $dD > d$) excepto cuando $D = 1$

Mínimo común múltiplo

Teorema 1.20 (Mínimo Común Múltiplo). *Dados $a, b \in \mathbb{Z}$, existe un único entero m que satisface:*

- $a|m$ y $b|m$
- Si existe M tal que $a|M$ y $b|M$ entonces $m|M$

*Este entero m se denomina **mínimo común múltiplo entre a y b** y se lo denota $[a, b]$ ó $\text{mcm}[a, b]$*

Observación 1.21. *Se puede demostrar que $|a.b| = (a, b)[a, b]$, luego $[a, b] = \frac{|a.b|}{(a, b)}$*

Números reales

Incluye a los racionales y a los irracionales

Con los números reales pueden realizarse todo tipo de operaciones básicas (suma, resta, producto, división y además potencias y raíces) con diversas excepciones importantes:

1. No existen raíces de orden par (cuadradas, cuartas, sextas, etc.) de números negativos en números reales
2. La división por cero no está definida (pues cero no posee inverso multiplicativo)
3. No se puede hallar el logaritmo de un número real negativo, cualquiera sea la base de logaritmos

El conjunto de los números reales junto con la suma y el producto usual, dotado del orden habitual que es compatible con estas operaciones, tiene estructura de **cuerpo**.

Números racionales

Definición 2.1. *Un **número racional** es todo número que puede representarse como el cociente de dos números enteros (o más precisamente, un entero y un natural positivo, o sea, podemos considerar que el denominador nunca es negativo)*
Es decir, una fracción común $\frac{a}{b}$ con numerador a y denominador b distinto de cero.

Los racionales incluyen a los enteros ($n = n/1$)

Densidad

Los números racionales cumplen la propiedad arquimediana o de *densidad*, esto es, para cualquier par de números racionales existe otro número racional situado entre ellos, propiedad que no está presente en los números naturales ni en los números enteros.

Una forma de mostrar que $\mathbb{Q}$ es denso es tomar dos números racionales y encontrar otro racional entre ellos.

Sean x e y en $\mathbb{Q}$. Supongamos que $x < y$, entonces $2x = x + x < x + y$ (y de la misma forma $x + y < y + y = 2y$)

Luego, $2x < x + y < 2y$, y dividiendo todo por 2 nos queda $x < \frac{x+y}{2} < y$

el número $z = \frac{x+y}{2}$ es el racional que existe entre x e y .

Números irracionales

Definición 2.3. *Un **número irracional** es un número que no puede ser expresado como cociente de dos enteros, es decir que no puede ser una fracción $\frac{m}{n}$ donde m y n sean enteros (con n diferente de cero)*

Propiedades

- La suma y la diferencia de un número racional y de un número irracional es un número irracional
- El producto de un racional diferente de cero por un irracional es un número irracional
- El cociente entre un racional no nulo y un irracional, es un número irracional
- El inverso de un número irracional es número irracional

Observación 2.5. *La suma y el producto de irracionales no son operaciones cerradas.*

Pensemos por ejemplo en el producto de $\sqrt{5}$ por si mismo, o si al número irracional π le restamos la “parte” decimal de π , queda 3 que es un número entero.

Números complejos

Definimos al número i (unidad imaginaria) como aquel número que satisface la siguiente igualdad:

$$i^2 = -1$$

Esto nos permite ampliar al conjunto de los números reales y por lo tanto escribiremos a un **número complejo** z de la siguiente forma:

$$z = a + ib, \quad a, b \in \mathbb{R}$$

Esta manera de introducir a los números complejos es a través de lo que llamamos *forma binómica del número complejo*

Luego el conjunto de números complejos, al que denotaremos como $\mathbb{C}$, se define por comprensión de la siguiente forma:

$$\mathbb{C} = \{z = a + ib; a, b \in \mathbb{R}; i^2 = -1\}$$

Observemos que si tenemos $b = 0$ “recuperamos” a los números reales

Si $a = 0$ decimos que el número complejo es un **imaginario puro**

Definición 3.1. Dado un número complejo $z = a + ib$, se definen la parte real y la parte imaginaria de z como:

$$\operatorname{Re}(z) = a \qquad \operatorname{Im}(z) = b$$

siendo $a, b \in \mathbb{R}$

Definición 3.2. Dos números complejos son **iguales** si lo son las partes reales e imaginarias respectivamente.

Es decir, dados dos números complejos z_1 y z_2 , vale la igualdad si :

$$\operatorname{Re}(z_1) = \operatorname{Re}(z_2) \qquad \text{y} \qquad \operatorname{Im}(z_1) = \operatorname{Im}(z_2)$$

Definición 3.3. El conjugado de un número complejo $z = a + ib$ se lo denota como $\bar{z}$ ó z^* y se lo define como:

$$\bar{z} = a - ib$$

Observamos que $\overline{(\bar{z})} = z$

Suma

$$z_1 + z_2 = (a_1 + a_2) + i(b_1 + b_2)$$

La suma es cerrada, asociativa, conmutativa y tiene neutro ($0 + 0i$)

Opuesto y resta

Definición 3.7. Dado un número complejo $z = a + ib$ se define el **opuesto** de z y se lo denota como $-z$ al complejo $-z = -a - ib$.

$$z_1 - z_2 = (a_1 + ib_1) - i(a_2 + ib_2) = (a_1 + ib_1) + (-a_2 - ib_2)$$

* El i en el 2do igual antes del 2do paréntesis está demás

Producto

Definición 3.9. *Dados dos números complejos $z_1 = a_1 + ib_1$ y $z_2 = a_2 + ib_2$, se define el producto de estos dos números como:*

$$\begin{aligned} z_1 \cdot z_2 &= (a_1 + ib_1) \cdot (a_2 + ib_2) = a_1a_2 + ia_1b_2 + ia_2b_1 + ib_1ib_2 \\ &= a_1a_2 + ia_1b_2 + ia_2b_1 + i^2b_1b_2 \\ &= a_1a_2 + ia_1b_2 + ia_2b_1 - b_1b_2 \\ &= (a_1a_2 - b_1b_2) + i(a_1b_2 + a_2b_1) \end{aligned}$$

El producto es cerrado, asociativo, conmutativo y tiene neutro ($1 = 1 + i0$)

Inverso y cociente

Definición 3.12. *Dado el número complejo $z = a + ib \neq 0 + i0$, se define el inverso de z y se lo denota como z^{-1} al siguiente número:*

$$z^{-1} = \frac{1 \cdot \bar{z}}{z \cdot \bar{z}} = \frac{a - ib}{(a + ib) \cdot (a - ib)}$$

Definición 3.14. *Dados dos números complejos $z_1 = a_1 + ib_1$ y $z_2 = a_2 + ib_2 \neq 0 + i0$, se define el cociente de estos dos números y se lo denota como $\frac{z_1}{z_2}$, al producto de z_1 con el inverso de z_2 es decir:*

$$\begin{aligned} \frac{z_1}{z_2} &= z_1 \cdot z_2^{-1} = \frac{(a_1 + ib_1) \cdot (a_2 - ib_2)}{(a_2 + ib_2)(a_2 - ib_2)} \\ &= \frac{(a_1a_2 + b_1b_2) + i(-a_1b_2 + a_2b_1)}{a_2^2 + b_2^2} \end{aligned}$$

Potencias de complejos

$$i^0 = 1$$

$$i^1 = i$$

$$i^2 = -1$$

$$i^3 = i^2 i = -1 \cdot i$$

$$i^4 = i^2 i^2 = -1 \cdot -1 = 1$$

Esto nos permite inferir que $i^m = i^r$ siendo $m = 4q + r$; $0 \leq r < 4$ ya que

$$i^m = i^{4q+r} = i^{4q} i^r = (i^4)^q i^r = 1^q i^r = 1 \cdot i^r = i^r$$

Representaciones

Par ordenado

Geométricamente, un número complejo puede representarse como un punto en el plano, como un *par ordenado*.

Un número complejo z sería un par ordenado (a, b) donde a es la parte real y b la parte imaginaria de mi complejo.


Se pueden definir en esta forma de manera natural la igualdad entre complejos como la igualdad entre pares ordenados (esto es, la primera coordinado del primer par debe ser igual a la primera coordenada del segundo par, y la segunda coordenada del primer par será igual a la segunda coordenada del segundo par); la suma de complejos y el producto por un escalar (por un real), siempre coordenada a coordenada.

Las operaciones de producto y cociente no son ya tan intuitivas.

La unidad imaginaria, nuestro i , se representará por el par $(0, 1)$.


Esta forma de representación es la que muchos eligen para introducir el conjunto de los números complejos.

El concepto de número complejo extiende así la recta real a un espacio bidimensional, el llamado **Plano Complejo**.



Módulo y argumento

De la representación en el plano complejo de un número z se puede ver que hay asociado a cada número complejo un número real que es su *distancia* al origen y llamaremos **módulo** del complejo y al que denotaremos como $|z|$, y un *ángulo* θ , que es el que forma el segmento de recta $|z|$ con el eje real positivo, al que llamaremos **argumento** de z y se definen de la siguiente forma:



$$\text{argumento de } z = \theta = \arctan(b/a)$$

Observemos que hay infinitos ángulos equivalentes a θ (es decir, ángulos que satisfacen que su tangente es igual a $\frac{b}{a}$) por eso tenemos que elegir el rango para que no haya confusión.

Nosotros en este curso vamos a pedir que $0 \leq \theta < 2\pi$

En términos de estos valores diremos que dos complejos z y w son **iguales** si :

$$\text{módulo de } z = |z| = |w| = \text{módulo de } w$$

$$\theta = \text{argumento de } z = \text{argumento de } w = \alpha + 2k\pi$$

Forma trigonométrica

$$\text{Re}(z) = a = |z| \cos(\theta)$$

$$\text{Im}(z) = b = |z| \sin(\theta)$$

$$z = a + ib = |z| \cos(\theta) + i|z| \sin(\theta) = |z| (\cos(\theta) + i \sin(\theta))$$

Forma exponencial

Usando la formula de Euler

$$e^{i\alpha} = \cos(\alpha) + i \sin(\alpha);$$

y la forma trigonométrica de un número complejo, obtenemos una forma cómoda de escribir a un número complejo z que se conoce como forma exponencial del complejo y se la define como:

$$z = |z|(\cos(\theta) + i \sin(\theta)) = |z|e^{i\theta}$$

Forma polar

La muy usada forma polar toma los elementos básicos, módulo y argumento. Es muy sencilla y práctica pero no es muy intuitiva para realizar operaciones.

$$z = |z|e^{i\theta}$$

Operaciones en forma exponencial

Producto y cociente

Dados dos números complejos escritos en su forma exponencial, $z_1 = |z_1|e^{i\alpha_1}$ y $z_2 = |z_2|e^{i\alpha_2}$, podemos escribir el producto y el cociente de dos número complejos de manera simple como:

$$z_1 z_2 = |z_1|e^{i\alpha_1}|z_2|e^{i\alpha_2} = |z_1||z_2|e^{i\alpha_1}e^{i\alpha_2} = |z_1||z_2|e^{i(\alpha_1+\alpha_2)}$$

$$\frac{z_1}{z_2} = \frac{|z_1|e^{i\alpha_1}}{|z_2|e^{i\alpha_2}} = \frac{|z_1|}{|z_2|}e^{i(\alpha_1-\alpha_2)}$$

Potencia

Notamos que al escribir un número complejo en su forma exponencial resulta fácil calcular el producto o el cociente de dos números complejos, de manera similar ocurre con la forma trigonométrica o polar (aunque hay que recordar reglas y propiedades), esto nos permite definir la potencia n de un número complejo de manera muy simple.

Sea $z = |z|e^{i\alpha}$, n un número natural,

$$z^n = \underbrace{z \dots z}_{n} = \underbrace{|z|e^{i\alpha} \dots |z|e^{i\alpha}}_n = \left(\underbrace{|z| \dots |z|}_n \right) \left(\underbrace{e^{i\alpha} \dots e^{i\alpha}}_n \right) = |z|^n e^{i(\alpha + \dots + \alpha)} = |z|^n e^{in\alpha}$$

Luego,

$$z^n = (|z|e^{i\alpha})^n = |z|^n e^{in\alpha}$$

Raíces n -ésimas

Definición 3.21. Dado un número complejo $z = |z|e^{i\alpha}$, se define a las **raíces n -ésimas de z** (y se las denota como $z^{1/n}$), como los números complejos w que satisfacen la siguiente ecuación $w^n = z$.

Definición 3.23. Las raíces n -ésimas de z están dadas por la siguiente expresión:

$$w_k = |z|^{1/n} e^{\frac{\alpha + 2k\pi}{n}}; 0 \leq k < n$$

Ejemplo 3.24. Calcular las raíces cuartas de $2 + 2i$

Ya habíamos obtenido la forma exponencial de este complejo, $z = 2\sqrt{2}e^{i\frac{\pi}{4}}$. Como habla de raíces cuartas entendemos que $n = 4$, entonces.

$$|w| = \sqrt[4]{|z|} = \sqrt[4]{2\sqrt{2}} = \sqrt[8]{2^3}$$

$$\varphi_k = \frac{\frac{\pi}{4} + 2k\pi}{4}; \quad 0 \leq k \leq 3$$

Entonces,

$$\varphi_0 = \frac{\frac{\pi}{4} + 2 \cdot 0 \pi}{4} = \frac{\frac{\pi}{4}}{4} = \frac{\pi}{16}$$

$$\varphi_1 = \frac{\frac{\pi}{4} + 2\pi}{4} = \frac{\frac{9\pi}{4}}{4} = \frac{9\pi}{16}$$

$$\varphi_2 = \frac{\frac{\pi}{4} + 4\pi}{4} = \frac{\frac{17\pi}{4}}{4} = \frac{17\pi}{16}$$

$$\varphi_3 = \frac{\frac{\pi}{4} + 6\pi}{4} = \frac{\frac{25\pi}{4}}{4} = \frac{25\pi}{16}$$

Por lo tanto, las raíces cuartas serán:

$$w_0 = \sqrt[8]{2^3} e^{i\frac{\pi}{16}}$$

$$w_1 = \sqrt[8]{2^3} e^{i\frac{9\pi}{16}}$$

$$w_2 = \sqrt[8]{2^3} e^{i\frac{17\pi}{16}}$$

$$w_3 = \sqrt[8]{2^3} e^{i\frac{25\pi}{16}}$$

Clase 4 - Relaciones entre conjuntos

Definición 0.1. *Una relacion n -aria sobre $A_1, \dots, A_n$ es un subconjunto del producto cartesiano $A_1 \times \dots \times A_n$*

Los conceptos básicos de una base de datos relacional son:

- Tablas: son las relaciones (que representan las bases de datos).
- Registros: son las n -tuplas
- Campos: son las entradas de las n -tuplas (elementos de los conjuntos).
- Atributos: son las columnas de cada tabla

Las relaciones 2-arias se llaman también **binarias**, entonces:

Dados dos conjuntos no vacíos A y B , una relación binaria definida entre los mismos es un subconjunto del producto cartesiano $A \times B$, caracterizado por alguna propiedad común a sus elementos

$$R = \{(x, y) / (x, y) \in A \times B\} \subset A \times B$$

Muchas veces cuando $(x, y) \in R$ escribiremos xRy y diremos que x está relacionado por R con y .

Dominio e imagen

Sea R una relación de A en B .

Se llama **dominio** de R al conjunto de elementos x de A tales que $(x, y) \in R$

$$Dom_R = \{x \in A : (x, y) \in R\}$$

Se llama **imagen** de R al conjunto de elementos y de B tales que $(x, y) \in R$

$$Im_R = \{y \in B : (x, y) \in R\}$$

Relación inversa

Sea R una relación de A en B . Se llama **relación inversa** de R al subconjunto de $B \times A$ definido por

$$R^{-1} = \{(y, x) : (x, y) \in R\}$$

Composición

Dadas las relaciones R en $A \times B$ y S en $B \times C$ se puede construir la relación composición

$$SoR = \{(x, z) : (x, y) \in R, (y, z) \in S\} \subset A \times C$$

Ojo que (x, y) pertenecen a R , que va segunda en SoR y (y, z) pertenecen a S que va primera en SoR

Matriz de una relación

Es posible representar una relación entre dos conjuntos finitos con una matriz.

Sea R una relación entre $A = \{a_1, \dots, a_m\}$ y $B = \{b_1, \dots, b_n\}$, la matriz de representación M_R de la relación está dada por:

$$m_{ij} = \begin{cases} 1 & (a_i, b_j) \in R \\ 0 & (a_i, b_j) \notin R \end{cases}$$

Ejemplos 1.6. • Sea $R = \{(1, r); (2, s); (3, r)\}$ una relación entre $A = \{1, 2, 3\}$ y $B = \{r, s\}$
Entonces la matriz de la relación será:

$$M_R = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \end{pmatrix}$$

• Dada la matriz

$$M = \begin{pmatrix} 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \end{pmatrix}$$

Podemos considerar que existe una relación R entre algún conjunto $A = \{a, b, c\}$ y otro conjunto $B = \{1, 2, 3, 4\}$ tal que $R = \{(a, 1); (a, 4); (b, 2); (b, 3); (c, 1); (c, 3)\}$

Relaciones binarias en un conjunto

Si una relación R es tal que $R \subset A \times A$, se dice que está definida en el conjunto A (o que R es una relación sobre A)

Propiedades

Reflexividad

R será reflexiva si para todo $x \in A$ vale que xRx .

Simetría

R será simétrica si para todo $x, y \in A$ vale que $xRy \Rightarrow yRx$.

Antisimetría

R será antisimétrica si para todo $x, y \in A$ vale que xRy e yRx implican que $x = y$.

Transitividad

R será transitiva si para todo $x, y, z \in A$ vale que xRy e yRz implican que xRz .

Obs: Vemos que las propiedades están definidas por un condicional entonces para probarlas debemos mirar bien que *si se cumple que el antecedente es Verdadero tiene que ser Verdadero también el consecuente para que todo el condicional sea Verdadero*, es decir los únicos casos **falsos** son los de antecedente Verdadero y consecuente Falso. Recordemos que de igual manera, *antecedente Falso hace que el condicional sea Verdadero, no importa cual sea el valor de verdad del consecuente*, entonces si no encontramos un par no tenemos que buscar su inverso u otro para componer para probar simetría, antisimetría o transnitividad.

Relaciones de orden

Preorden:

- Reflexiva
- Transitiva

Orden:

- Reflexiva
- Antisimétrica
- Transitiva

Orden parcial y total

Muchas veces diremos que la relación ordena S y la notaremos por $\leq$ (no confundir este símbolo con el orden de los números reales, el orden de los reales es un ejemplo más de orden).

Obs: Si bien nosotros diremos que una relación con estas propiedades es un orden muchas veces vamos a encontrar que a este tipo de relaciones se las denomina **orden parcial**. Un orden parcial refiere a una relación donde hay elementos que no son comparables.

Si cada par de elementos en un conjunto es comparable diremos que el orden es **total** o **lineal**.

Con esto se pretende formalizar la idea intuitiva de orden de un conjunto.

Definición 2.5. Dado un conjunto ordenado (A, R) se dice que dos elementos a, b del conjunto son **comparables** si se verifica que aRb ó bRa , en caso contrario se dice que son **incomparables**.

Si todos los elementos de A son comparables dos a dos entonces se dice que A está **totalmente ordenado** y que R es un **orden total** en A . Si existen elementos incomparables se dirá que R es un **orden parcial** en A .

Orden producto y orden lexicográfico

Definición 2.6. Sean $(A_1, R_1), (A_2, R_2), \dots, (A_n, R_n)$ una familia de conjuntos ordenados.

- Se llama relación **orden producto** (estándar) a la relación $R \subset A_1 \times A_2 \times \dots \times A_n$ definida por: $(x_1, x_2, \dots, x_n)R(y_1, y_2, \dots, y_n)$ si y sólo si $x_1R_1y_1, x_2R_2y_2, \dots, x_nR_ny_n$ para todo $i = 1, \dots, n$
- Se llama relación **producto lexicográfico** a la relación $L \subset A_1 \times A_2 \times \dots \times A_n$ definida por: $(x_1, x_2, \dots, x_n)L(y_1, y_2, \dots, y_n)$ si y sólo si $x_i = y_i$ para todo $i = 1, \dots, n$, ó $x_jR_jy_j$ siendo j el primer índice tal que $x_j \neq y_j$

Conjuntos ordenados

Un conjunto A junto con un orden (parcial/total) R es un **conjunto ordenado**. (*conjunto parcialmente/totalmente ordenado*).

Generalmente se dice que R ordena al conjunto A y se denota (A, R) .

Diagramas de Hasse

Un diagrama de Hasse es una *versión simplificada* de un digrafo. Es una herramienta muy útil ya que describe completamente el orden asociado.

Elementos extremos

Algunos elementos de un conjunto ordenado tienen especial importancia para muchas propiedades y aplicaciones de los conjuntos ordenados.

Definición 2.8. Sea $(A, <)$ un conjunto ordenado cualquiera.

Diremos que un elemento $a \in A$ es un **elemento máximo de A** si $x < a$ para todo $x \in A$. De manera dual, un elemento $a \in A$ es un **elemento mínimo de A** si $a < x$ para todo $x \in A$.

Definición 2.9. Sean $(A, <)$ un conjunto ordenado cualquiera y B un subconjunto de A .

- Un elemento $a \in A$ es una **cota superior de B** si $b < a$ para todo $b \in B$
- Un elemento $a \in A$ es una **cota inferior de B** si $a < b$ para todo $b \in B$.
- Un elemento $a \in A$ se llama **supremo** de B (*mínima cota superior de B*) si a es cota superior de B y $a < c$ para toda c cota superior de B
- Un elemento $a \in A$ se llama **ínfimo** de B (*máxima cota inferior de B*) si a es cota inferior de B y $c < a$ para toda c cota inferior de B

Relaciones de equivalencia

Equivalencia:

- Reflexiva
- Simétrica
- Transitiva

La idea de equivalencia sobre un conjunto permite establecer una relación entre los elementos del conjunto que comparten cierta característica o propiedad. Esto permitirá reagrupar dichos elementos.

Clases de equivalencia

Definición 2.12. Dada una relación de equivalencia R sobre A y un elemento $a \in A$ se denominará **clase de equivalencia de a por R** y se denotará $\bar{a}$ (ó $R(a)$) al conjunto de todos los elementos de A que están relacionados con a por R . Es decir, $\bar{a} = \{x \in A : xRa\}$

Cualquier elemento de $\bar{a}$ se llama **representante** de la clase, y en particular, como la relación es reflexiva se da que $a \in \bar{a}$, luego a es representante de la clase $\bar{a}$ para todo $a \in A$.

Conjunto cociente

Definición 2.14. Al conjunto formado por todas las clases de equivalencia de elementos del conjunto A respecto de la relación R se lo llamará **conjunto cociente de A respecto de la relación R** y se lo denotará: $A/R = \{\bar{a} : a \in A\}$

Partición

Definición 2.15. Una **partición** de un conjunto A es un conjunto de partes no vacías de A , disjuntas dos a dos y tales que su unión coincide con A .

Esto es, dado A un conjunto, y $P = \{A_i\}$ con $i \in I$ (una familia de subconjuntos de A). Se dice que P es una partición de A si y sólo si se verifican:

- Si $A_i \in P$ entonces $A_i \neq \emptyset$
- Si $A_i, A_j \in P$ entonces $A_i \cap A_j = \emptyset$ para $i \neq j$
- $\bigcup_{i \in I} A_i = A$

Es decir, una división de un conjunto no vacío en “partes” separadas y no vacías representadas mediante una colección o familia de subconjuntos de dicho conjunto que lo recubren.

Notación: Si bien estamos usando la P para referirnos a las particiones, en general una partición suele anotarse con la letra π

Sea P una partición de un conjunto A .

Definiremos sobre A la siguiente relación R : aRb si y sólo si existe $X \in P$ tal que $a, b \in X$

Claramente R es reflexiva ya que al ser P una partición de A todo elemento del conjunto pertenece a algún subconjunto de la familia P .

Es inmediata la simetría de R (si existe $X \in P$ tal que $a, b \in X$, existirá (ese mismo) X tal que $b, a \in X$).

Sólo falta comprobar la transitividad de R para poder afirmar que es una relación de equivalencia: queremos probar que si dados $a, b, c \in A$ tales que aRb y bRc entonces aRc .

Si aRb y bRc entonces existen $X, Y \in P$ tales que $a, b \in X$ y $b, c \in Y$, luego $b \in X \cap Y$ pero como $X, Y \in P$ pero como P es una partición sus elementos tienen intersección vacía, con lo cual o no existe b o $X = Y$ y por lo tanto $a, c \in Y = X$ y aRc .

La relación R definida de esta forma es llamada **equivalencia asociada a la partición P**

Lema 2.18. *Sea R una relación de equivalencia en un conjunto A , entonces para todos par a, b de elementos de A vale que $\bar{a} = \bar{b}$ si y sólo si aRb*

Supongamos que $\bar{a} = \bar{b}$, como R es reflexiva aRa entonces $a \in \bar{a} = \bar{b}$, luego $a \in \bar{b}$ y aRb . Ahora suponemos que aRb y probaremos que las clases son iguales:
Sea $z \in \bar{a}$, entonces zRa pero como R es de equivalencia, por transitividad y la hipótesis general aRb tenemos que zRb , luego $\bar{a} \subset \bar{b}$. De la misma manera podemos ver que vale la otra inclusión y por lo tanto, $\bar{a} = \bar{b}$.

Teorema 2.19. *Si R es una relación de equivalencia en un conjunto A , el conjunto cociente A/R es una partición de A .*

Demostración: Queremos mostrar que A/R (el conjunto de todas las clases de equivalencia por R) particiona a A

Veamos que cumple con la definición, o sea que es un conjunto de partes no vacías de A disjuntas dos a dos y que su unión es A

Como R es reflexiva, para todo $a \in A$ vale que aRa y por lo tanto $\bar{a} = R(a)$ es no vacío.
Supongamos que existe $x \in R(a) \cap R(b)$, luego xRa y xRb . Como R es simétrica y transitiva (por ser de equivalencia) aRb pero esto significa que las clases son iguales. Entonces todas las partes o son iguales o son disjuntas

Por definición todas las clases de equivalencia por R sobre A son subconjuntos de A y por lo tanto la unión de todas ellas está incluida en A .

Como todo elemento $a \in A$ pertenece a su propia clase $\bar{a} = R(a)$ (por ser R reflexiva), vemos que todo elemento de A es un elemento en la unión de todas las clases.

Relación de congruencia

Definición 2.21. *Dados los enteros a, b y m , se dice que a es congruente con b módulo m y se escribe $a \equiv b \pmod{m}$ (ó $a \equiv_m b$ ó $a \equiv b \pmod{m}$) si y sólo si $m|a - b$, es decir, existe $k \in \mathbb{Z}$ tal que $a - b = k.m$*

Proposición 2.23. *La relación de congruencia módulo m es una relación de equivalencia*

Demotración: Para mostrar que la congruencia es una relación de equivalencia tenemos que probar que es reflexiva, simétrica y transitiva.

Tenemos: a es congruente con b módulo m , ó $a \equiv_m b$ si y sólo si $m|a - b$, entonces,

- $\equiv_m$ es reflexiva ya que para a entero vale que $m|a - a$ pues $a - a = 0.m$
- $\equiv_m$ es simétrica.

Supongamos que $a \equiv_m b$, entonces m divide a $a - b$ y existe k entero tal que $a - b = k.m$, luego existe $-k$ tal que $b - a = -(a - b) = -(k.m) = (-k).m$ y por lo tanto $m|b - a$ y $b \equiv_m a$

- $\equiv_m$ es transitiva: esto es, si $a \equiv_m b$ y $b \equiv_m c$ entonces $a \equiv_m c$

Supongamos que $a \equiv_m b$ entonces $m|a - b$, existe k entero tal que $a - b = km$,

por otro lado $b \equiv_m c$ entonces $m|b - c$, existe h entero tal que $b - c = hm$,

luego $a - c = a + (-b + b) - c = (a - b) + (b - c) = km + hm = (k + h)m$, y existe un entero $t = k + h$ tal que $a - c = tm$ y así m divide a $a - c$ y de esa forma tenemos que $a \equiv_m c$ como queríamos probar.

Por ser la congruencia una relación de equivalencia en $\mathbb{Z}$, determina una partición del conjunto de los números enteros en *clases de equivalencia* que se denominan *clases de congruencia módulo m* .

La clase de congruencia módulo m de un número x será el conjunto $\bar{x} = \{y \in \mathbb{Z} : y \equiv_m x\}$

Esto nos permite agrupar a los enteros en familias disjuntas de manera que dos números son congruentes módulo m si y sólo si están en la misma clase de equivalencia.

Esta partición de $\mathbb{Z}$ inducida por la congruencia módulo m es lo que nos determina el conjunto cociente $\mathbb{Z}/m = \mathbb{Z}_m = \mathbb{Z}/\equiv_m$ que estaremos estudiando.

Proposición 2.25. *Todo entero es **congruente módulo** m con su **resto** en la división por m*

Demostración:

Supongamos que $x \equiv_m y$, sabemos que esto equivale a decir que existe k entero tal que $x - y = km$, entonces podemos escribir $x = km + y$.

Como antes dijimos que dos enteros son congruentes si pertenecen a la misma clase podemos con ésto describir las clases de la siguiente forma:

$$\bar{x} = \{y : y \equiv_m x\} = \{y : x = km + y\} = \{y : y = x + k'm\} = \{y : y = x, y = x + 1, y = x + 2, \dots\}$$

Proposición 2.27. *Dos enteros son congruentes módulo m si y sólo si los respectivos restos en su división por m son iguales.*

Demostración:

Supongamos que x e y son dos enteros congruentes módulo m y probemos que tienen el mismo resto en la división por m .

Por el algoritmo de la división, existen (y son únicos) cociente y resto enteros tales que :

$$x = k_1m + r_1 \text{ con } 0 \leq r_1 < m$$

$$y = k_2m + r_2 \text{ con } 0 \leq r_2 < m \quad (\text{Observemos que } |r_1 - r_2| < m)$$

$$\text{Luego, } x - y = (k_1m + r_1) - (k_2m + r_2) = (k_1m - k_2m) + (r_1 - r_2) = (k_1 - k_2)m + (r_1 - r_2)$$

Y como $x \equiv_m y$, existe un entero k tal que $x - y = km$, concluimos que debe ser $r_1 - r_2 = 0$ y por lo tanto $r_1 = r_2$.

Ahora supongamos que los restos en la división por m coinciden y veremos que $x \equiv_m y$.

Otra vez usando el algoritmo de la división existen k_1, k_2, r enteros tales que :

$$x = k_1m + r$$

$$y = k_2m + r$$

$$\text{Así, } x - y = (k_1m + r) - (k_2m + r) = (k_1m - k_2m) + (r - r) = (k_1 - k_2)m = km$$

mostrando que $m|x - y$ y por lo tanto, $x \equiv_m y$.

Todo entero es congruente con su resto en la división por m , $x \equiv_m r$, ya que por el algoritmo de la división para cualquier entero x existe y es único el resto r en la división por m .

También sabemos que dos enteros congruentes pertenecen a la misma clase de equivalencia, y por lo tanto las clases serán iguales, $\bar{x} = \bar{r}$.

Por las propiedades y características de la división entera, tenemos que hay m posibles restos en la división por m . Estos son, $0, \dots, m - 1$.

De esta forma vemos que habrá m clases de equivalencia o congruencia.

Teorema 2.29. Sea $m \in \mathbb{N}$, $\mathbb{Z}_m = \mathbb{Z}/\equiv_m$, el conjunto cociente, tiene m clases de equivalencias.

Clase 5 - Estructuras algebraicas

Una Estructura Algebraica es un conjunto no vacío dotado con una o más operaciones. Estas operaciones están definidas en el producto cartesiano (pueden ser n-arias aunque aquí vamos a concentrarnos en operaciones unarias y binarias) y serán cerradas.

Bien definida

Esto es, supongamos que A es el conjunto no vacío, si a cada elemento del producto cartesiano se le asigna unívocamente un elemento del conjunto A diremos que la operación está bien definida, o que es una operación n-aria en A .

Propiedades de las operaciones binarias

Conmutativa

$*$ es conmutativa si, para todo a y $b \in A$, resulta $a * b = b * a$.

Asociativa

$*$ es asociativa si, cualesquiera sean a, b y $c \in A$, resulta $a * (b * c) = (a * b) * c$.

Elemento neutro

$(A, *)$ tiene elemento neutro si existe en A un elemento e tal que para todo $a \in A$ vale que $a * e = e * a = a$.

Si existe, es único

Elemento inverso

Si $(A, *)$ tiene un elemento neutro e , se dirá que un elemento $a \in A$ tiene inverso si existe $a' \in A$ tal que $a * a' = a' * a = e$.

Si existe el inverso, es único y vale la propiedad cancelativa: $a * b = a * c; \Rightarrow; b = c$

Potencia

Sea $(S, *)$ un semigrupo. Para cualquier $a \in S$ definimos:

$$a^1 = a$$

$$a^n = a * a^{n-1} \quad n = 2, 3, 4, \dots$$

Proposición 1.2. Dado un semigrupo $(S, *)$, $a \in S$ y m, n naturales, valen:

$$a^m * a^n = a^{m+n} \quad (a^m)^n = a^{m \cdot n}$$

- a^{-n} será el resultado de la operación $a^{-1} * a^{-1} * \dots * a^{-1}$
- $(a^n)^{-1} = a^{-n}$

Se tiene, por definición, $a^n * a^{-n}$, por lo que obtenemos $a^0 = e$

Tipos de estructuras

Grupoide

Si es una operación binaria

Semigrupo

Si es una operación binaria asociativa

Si además es conmutativa $\Rightarrow$ semigrupo conmutativo

Monoide

Si es una operación binaria asociativa y con elemento neutro

Si además es conmutativa $\Rightarrow$ monoide conmutativo

Grupo

Si es una operación binaria asociativa, con elemento neutro e inverso

Si es conmutativa $\Rightarrow$ grupo conmutativo o abeliano

Anillo

Dadas dos operaciones $+$ y $*$, $(A, +, *)$ es un anillo si $(A, +)$ es un grupo abeliano y $*$ es asociativa y distributiva a izquierda y derecha con respecto a $+$.

Si $*$ es conmutativa $\Rightarrow$ es un anillo conmutativo.

Si existe un elemento $a \in A$ que sea el neutro para $*$ y es diferente del neutro para $+$, entonces ese elemento a es el elemento unitario.

Un anillo conmutativo es un dominio de integridad si se cumple que para todo $a, b \in A$, $a * b = 0$ implica $a = 0$ o $b = 0$.

Propiedades de los grupos

Cualquiera sea $a \in G$, $(a^{-1})^{-1} = a$.

Cualesquiera sean $a, b \in G$, $(ab)^{-1} = b^{-1}a^{-1}$.

Grupo producto

Teorema 2.1. Si $(G_1, *_1), (G_2, *_2), \dots, (G_m, *_m)$ son grupos, entonces $G = G_1 \times G_2 \times \dots \times G_m$ es un grupo con la operación $*$ definida por

$$(a_1, \dots, a_m) * (b_1, \dots, b_m) = (a_1 *_1 b_1, \dots, a_m *_m b_m)$$

Grupo cíclico

Definición 2.2. Un grupo G se dice que es **cíclico** si existe $a \in G$ tal que para todo elemento $b \in G$ existe un entero k tal que $b = a^k$.

En este caso decimos que a es un **generador** de G y escribimos $G = \langle a \rangle$

Todo grupo cíclico es abeliano

Orden

Definición 2.5. Sea G un grupo y a un elemento de G , diremos que a es de orden finito si existe un k natural tal que $a^k = e$. En ese caso, definimos el **orden de a** por $o(a) = \min k \in \mathbb{N} : a^k = e$

Teorema 2.6. *Grupos cíclicos finitos*

Si G es un grupo cíclico de orden m , entonces $G = \{e, a, a^2, \dots, a^{m-1}\}$

Subgrupo

Definición 2.7. *Dado un grupo $(G, *)$ y dado $H \subset G$, si $(H, *)$ constituye en sí mismo un grupo se dice que es un **subgrupo** de G .*

Observar que es la misma operación $$*

La asociatividad de $*$ en H está garantizada pues se cumple para todos los elementos de G , en particular se cumple para los de H

También si $*$ es conmutativa en G será conmutativa en H .

Luego, para que H sea subgrupo (o sea, un grupo) sólo será necesario que:

- $e \in H$, el elemento neutro de $*$ en G debe estar en H (*recordemos que el neutro es único*)
- $a, b \in H \rightarrow a * b \in H$, la operación debe ser cerrada en H (*era cerrada en G*)
- $a \in H \rightarrow a^{-1} \in H$, cada elemento de H tiene su inverso en H (*sabemos que el inverso existe pero en G , hay que asegurar que esté en H*)

Proposición 2.9. *Dado un grupo $(G, *)$, un subconjunto $H \subset G$ resultará un subgrupo de G si y sólo si :*

- $e \in H$
- si $a, b \in H$ entonces $a * b^{-1} \in H$

Teorema 2.10. *Si $(G, *)$, es un grupo cíclico y $(H, *)$ es un subgrupo de $(G, *)$, entonces $(H, *)$ es cíclico.*

Morfismos de grupos

Definición 2.11. *Dados dos grupos $(G_1, *)$ y $(G_2, \otimes)$ se dirá que una función $f : G_1 \rightarrow G_2$ es un **morfismo de grupos** si y sólo si “respetar” las operaciones, en la siguiente forma:*

$$f(a * b) = f(a) \otimes f(b) \text{ para todo } a, b \in G_1$$

(esto es: cuando se opera en G_1 , las correspondientes imágenes resultan operadas en G_2).

Un morfismo que es además inyectivo recibe el nombre de **monomorfismo**.

Un morfismo sobreyectivo se denomina **epimorfismo** y si es biyectivo, **isomorfismo**

Proposición 2.13. *Sean los grupos $(G_1, *)$ y $(G_2, \otimes)$ y $f : G_1 \rightarrow G_2$ un morfismo entre ellos, entonces $f(e_1) = e_2$ (siendo e_1 y e_2 los neutros respectivos a cada grupo).*

Además para cualquier $a \in G_1$, $f(a^{-1}) = (f(a))^{-1}$

Núcleo e imagen

Definición 2.14. *Sean los grupos $(G_1, *)$ y $(G_2, \otimes)$ y $f : G_1 \rightarrow G_2$ un morfismo entre ellos.*

*Se denomina **núcleo** del morfismo f al conjunto $Nu(f) = \{a \in G_1 : f(a) = e_2\}$ es decir al subconjunto del dominio formado por todos los elementos cuya imagen es el neutro del codominio.*

*Se denomina **imagen** del morfismo f al conjunto $Im(f) = \{b \in G_2 : \exists a \in G_1, f(a) = b\}$*

Proposición 2.16. *Sean los grupos $(G_1, *)$ y $(G_2, \otimes)$.*

Si $f : G_1 \rightarrow G_2$ un morfismo de grupos entonces $Nu(f)$ e $Im(f)$ son subgrupos de G_1 y G_2 respectivamente

Aritmética modular

La aritmética modular es una forma de representar números para que su valor nunca exceda un cierto límite, llamado modelo.

Dado $m \in \mathbb{Z}$, definiremos la suma y el producto entre los elementos de $\mathbb{Z}_m$, es decir entre las clases de equivalencia módulo m .

Esta definición no dependerá del representante elegido y así podremos sumar y multiplicar clases de equivalencias y el resultado será un representante de la misma clase (es decir, las operaciones estarán bien definidas).

La relación de congruencia es *compatible* con la suma y el producto.

Dados $a, b, c, d \in \mathbb{Z}$ tales que $a \equiv_m b$ y $c \equiv_m d$. Entonces se cumple que:

- $a + c \equiv_m b + d$
- $a \cdot c \equiv_m b \cdot d$

Operaciones

Suma

$$\bar{x} + \bar{y} = \overline{x + y}$$

La suma es un grupo abeliano

Producto

$$\bar{x} \cdot \bar{y} = \overline{x \cdot y}$$

El producto es un monoide conmutativo y se distribuye en la suma, por lo que forma un anillo conmutativo con la suma

Elementos invertibles

Definición 3.1. Dado $\bar{a} \in \mathbb{Z}_m$ no nulo, decimos que $\bar{a}$ es **divisor de 0** si: existe $\bar{b} \in \mathbb{Z}_m, \neq 0$ tal que $\bar{a} \cdot \bar{b} = \bar{0}$

Los divisores de cero son elementos distintos de $\bar{0}$ tal que su producto por otro elemento distinto de $\bar{0}$ da como resultado $\bar{0}$.

Definición 3.2. Dado $\bar{a} \in Z_m$, decimos que $\bar{a}$ es **invertible** (o divisor de la unidad), si: existe $\bar{c} \in Z_m$ tal que $\bar{a} \cdot \bar{c} = \bar{1}$

Teorema 3.3. Sea $\bar{a} \in Z_m$, $\bar{a}$ es invertible si y sólo si $(a, m) = 1$

Corolario 3.4. Si $m \in \mathbb{Z}$ es primo, Z_m es un cuerpo

Teorema 3.5. Dado $a \in Z_m$, a es invertible si y sólo si a NO es divisor de 0

Cosas raras

Teorema 3.6. Si p primo entonces $\bar{a}^p \equiv_p \bar{a}$. En particular, si $\bar{a} \neq \bar{0}$ se tiene que $\bar{a}^{p-1} \equiv_p \bar{1}$

Definición 3.7. La función ϕ , llamada **función de Euler**, es tal que a cada número natural m le asocia el número $\phi(m)$ de elementos invertibles de Z_m

Teorema 3.8. Teorema de Euler

Sean a y m enteros tales que $(a, m) = 1$, entonces $\bar{a}^{\phi(m)} \equiv_m \bar{1}$

Aplicaciones a la criptografía

RSA

1. Elegir 2 números primos (muy grandes) p y q
2. Calcular el módulo r donde $r = p \cdot q$ (fácil de calcular, difícil de revertir)
3. Calcular la función de Euler $\phi = (p - 1) \cdot (q - 1)$
4. Elegir un número e mayor que 1 y menor que ϕ que sea coprimo con ϕ
5. e es el exponente público. Las claves públicas son $\{r, e\}$
6. El exponente privado d es la inversa de e módulo ϕ ($e \cdot d \equiv_{\phi} 1$)

Se puede entonces hacer públicos e y r ya que nadie puede encontrar d usándolos

Para encriptar un mensaje m se eleva el mensaje a e y se aplica módulo r , es decir, el texto cifrado c se calcula: $c \equiv_r m^e$

Para desencriptar un texto encriptado, se lo eleva a la potencia d y se aplica módulo r : $m \equiv_r c^d$

Entonces:

- p, q, ϕ y d son privadas
- e y r son públicas

Clase 6 - Álgebra lineal

Espacio vectorial

Definición 1.1. *Un **Espacio Vectorial sobre el cuerpo K** es una estructura algebraica $(V, +, \cdot)$ creada a partir de un conjunto no vacío V , una operación interna “+” llamada suma (definida sobre los elementos del conjunto V), y una operación externa “ $\cdot$ ” llamada producto por escalar (definida entre dicho conjunto y el cuerpo matemático K , que serán los reales o los complejos).*

Propiedades a cumplir

Esto es, Dado $(V, +, \cdot)$ sobre K , se tiene que:

“+” es cerrado en V , es decir, $\forall v_1, v_2 \in V, v_1 + v_2 \in V$.

“ $\cdot$ ” es cerrado en V , es decir, $\forall v \in V$ y $\forall k \in K, k \cdot v \in V$.

Además, se deben satisfacer los siguientes 8 axiomas que se pueden separar en dos clases:

Para la operación “suma” (“+”):

- “+” debe ser conmutativa, es decir: $\forall v_1, v_2 \in V; v_1 + v_2 = v_2 + v_1$.
- “+” debe ser asociativa: $\forall v_1, v_2, v_3 \in V; (v_1 + v_2) + v_3 = v_1 + (v_2 + v_3)$.
- Existencia del elemento *neutro* para “+”, es decir, $\exists 0 \in V : v + 0 = v, \forall v \in V$.
- Existencia del *opuesto*, es decir, $\forall v \in V, \exists -v \in V : v + (-v) = 0$.

Mientras que para la operación “producto por escalar” (“.”)

- “.” sea asociativa: $\forall \alpha, \beta \in K$ y $\forall v \in V$; $(\alpha\beta).v = \alpha(\beta.v)$.
- “.” sea distributiva respecto de la suma de escalares $\forall \alpha, \beta \in K$ y $\forall v \in V$; $(\alpha + \beta).v = \alpha.v + \beta.v$.
- “.” sea distributiva respecto de la suma de vectores: $\forall \alpha \in K$ y $\forall v_1, v_2 \in V$; $\alpha.(v_1 + v_2) = \alpha.v_1 + \alpha.v_2$.
- $\forall v \in V, \exists 1 \in K : 1.v = v$.

Teorema 1.3. *Sea V un espacio vectorial. Entonces:*

- *Para todo escalar α vale que $\alpha.0 = 0$*
- *Para todo $v \in V$, se cumple $0.v = 0$*
- *Si $\alpha.v = 0$ entonces $\alpha = 0$ o $v = 0$ (o ambos son nulos)*
- *Para todo $v \in V$ vale que $-1v = -v$*

Subespacio vectorial

Definición 1.4. *Un subespacio S de un espacio vectorial V es cualquier subconjunto (no vacío) S de V tal que él mismo es un espacio vectorial. Esto es, un subconjunto S de V que es cerrado bajo las operaciones de suma de vectores y multiplicación por un escalar.*

Como S es subconjunto de V todos sus elementos pertenecen al espacio, entonces 6 de los 8 axiomas/propiedades se satisfacen automáticamente (“se heredan” de V).

Sólo la condición de clausura (ser cerrado para las operaciones) debe ser examinada y verificada para determinar si S es un “subespacio vectorial”. Obviamente, S debe ser no vacío y esto se puede verificar mostrando que el elemento neutro de V pertenezca a S .

Proposición 1.5. *Sea V espacio vectorial, y sea $S \subset V$. Entonces S es un subespacio de V si y sólo si se satisfacen las siguientes condiciones:*

1. $S \neq \emptyset$
2. $\forall s_1, s_2 \in S \rightarrow s_1 + s_2 \in S$.
3. Dado $k \in K$ y $\forall s \in S \rightarrow k.s \in S$.

Combinación lineal

Definición 1.7. *Dado un conjunto de vectores $S = \{v_1, v_2, \dots, v_r\}$ del espacio vectorial V , se llama **combinación lineal** de los vectores de S , a los vectores v de la forma $v = c_1v_1 + c_2v_2 + \dots + c_rv_r$, donde los coeficientes $c_1, c_2, \dots, c_r$ son escalares.*

Espacio generado

Teorema 1.9. *Si $S = \{v_1, v_2, \dots, v_r\}$ son vectores del espacio vectorial V , entonces el conjunto de todas las combinaciones lineales de $v_1, v_2, \dots, v_r$, denotado $\text{gen}(S) = \langle v_1, v_2, \dots, v_r \rangle$ es un subespacio de V .*

Definición 1.10. *Al conjunto de todos los vectores que se obtienen como combinación lineal de los vectores de S se lo denomina **el espacio generado por S***

Conjunto generador

Definición 1.12. Se dice que el conjunto $S = \{v_1, v_2, \dots, v_r\}$ es un conjunto generador del espacio vectorial V si y sólo si todo vector de V puede escribirse como combinación lineal de $v_1, v_2, \dots, v_r$.

Esto es lo mismo que decir que $V = \text{gen}(S)$, ya que siempre vale que $\text{gen}(S) \subset V$ y si S es un conjunto generador entonces todo $v \in V$ puede escribirse como combinación lineal de vectores de S y por lo tanto $V \subset \text{gen}(S)$.

Independencia lineal

Un conjunto de generadores minimal para V será aquel conjunto S de vectores que no tenga elementos redundantes o innecesarios, es decir, todos los vectores del conjunto S deben ser necesarios para generar V .

Por tanto ninguno de los vectores de S puede ser combinación lineal de los otros para así asegurarnos que no hay elementos redundantes

Definición 1.15. Los vectores $v_1, v_2, \dots, v_r$ de un espacio vectorial V se dicen **linealmente dependientes** si existen escalares $c_1, c_2, \dots, c_r$ no todos nulos tales que $c_1v_1 + c_2v_2 + \dots + c_rv_r = 0$

Equivalentemente,

Definición 1.16. Los vectores $v_1, v_2, \dots, v_p$ de un espacio vectorial V se dicen **linealmente independientes** si la combinación $c_1v_1 + c_2v_2 + \dots + c_pv_p = 0$ implica que todos los c_i son nulos.

Una combinación lineal de un conjunto S de vectores *linealmente independientes* es única. Esto es, existe una única manera de expresar un vector particular como combinación lineal de los vectores de S linealmente independientes.

Es decir, con un conjunto S de vectores linealmente independientes, sólo puedo expresar un vector v como combinación lineal de una sola manera

Base de un espacio vectorial

Definición 1.18. Un conjunto de vectores $v_1, v_2, \dots, v_r$ forma una **base** del espacio vectorial V , si y sólo si:

1. $\{v_1, v_2, \dots, v_r\}$ son linealmente independientes, y
2. $\{v_1, v_2, \dots, v_r\}$ generan V .

Teorema 1.20. Si $B = \{v_1, \dots, v_n\}$ es una base de un espacio vectorial V , todo conjunto $M = \{u_1, \dots, u_m\}$ de $m > n$ vectores de V es linealmente dependiente

Corolario 1.21. Si $B = \{v_1, \dots, v_n\}$ y $B' = \{u_1, \dots, u_m\}$ son dos bases de un espacio vectorial V , entonces $m = n$

Es decir, **todas** las bases de un espacio vectorial V (finitamente generado) tienen el mismo número de elementos.

Dimensión

Definición 1.22. Si una base de un espacio vectorial V tiene n vectores, se dice que V tiene dimensión **n** .

En particular, el subespacio $\{0\}$ se dice que tiene *dimensión 0*.

Un espacio vectorial V se dice de *dimensión finita* si existe un conjunto *finito* de vectores que lo generan. En caso contrario se dice que V tiene *dimensión infinita*.

Teorema 1.23. Si V es un espacio vectorial de “dimensión n ” ($n > 0$) entonces

1. Cualquier conjunto de n vectores “linealmente independientes” de V genera todo V (forman una base de V). Además
2. Todo conjunto de n vectores que generan V son “linealmente independientes” (o sea, forman una base de V).

Esto dice que si sabemos la dimensión del espacio y tenemos la cantidad necesaria de vectores no hace falta probar las dos condiciones para ser base, con alguna de las dos bastará.

Transformaciones lineales

Definición 2.1. Una transformación lineal es una aplicación de un espacio vectorial V en otro espacio vectorial W , y se la denota como $L : V \rightarrow W$, si satisface:

- $\forall v_1, v_2 \in V, L(v_1 + v_2) = L(v_1) + L(v_2)$ y
- $\forall \alpha \in K \text{ y } \forall v \in V, L(\alpha.v) = \alpha.L(v)$.

Ó, equivalentemente, $\forall \alpha, \beta \in K \text{ y } \forall v_1, v_2 \in V, L(\alpha v_1 + \beta v_2) = \alpha L(v_1) + \beta L(v_2)$.

Propiedades

Propiedades 2.4. Dada una transformación lineal $L : V \rightarrow W$, se cumplen las siguientes propiedades:

- $L(0_v) = 0_w$.
- $\forall v \in V, L(-v) = -L(v)$.
- Si $v_1, \dots, v_n \in V$ entonces $L(\alpha_1 v_1 + \dots + \alpha_n v_n) = \alpha_1 L(v_1) + \dots + \alpha_n L(v_n)$.

Como **toda** transformación lineal cumple estas propiedades, podemos usarla para mostrar que si una aplicación no la cumple, entonces esa aplicación no es lineal.

En particular es muy útil la propiedad de que toda transformación “lleva el cero al cero” pero no hay que confundirse! la utilidad proviene de utilizar la contrarrecíproca de la propiedad. Es decir, si no cumple la propiedad no es una transformación lineal, si la cumple hay que seguir mirando.

Imagen y núcleo

Definición 2.5. Sea $L : V \rightarrow W$ una transformación lineal entre los espacios vectoriales V y W , se definen:

El Núcleo de una transformación lineal L es el conjunto de vectores $v \in V$ que son transformados o “enviados” al vector nulo 0_w de W . Es decir,

$$Nu(L) = \{v \in V : L(v) = 0_w\}$$

La Imagen de la transformación lineal L es el conjunto de vectores $w \in W$ que son imagen por L de elementos $v \in V$ y se denota como $Im(L)$ ó $L(V)$.

$$Im(L) = \{w \in W : \exists v \in V w = L(v)\}$$

Teorema 2.7. Si $L : V \rightarrow W$ es una transformación lineal entre los espacios vectoriales V y W , entonces:

1. El núcleo $Nu(L)$ es un subespacio de V .
2. La imagen $Im(L)$ es un subespacio de W .

Teorema 2.9. Si $L : V \rightarrow W$ es una transformación lineal entre los espacios vectoriales V y W de dimensión finita, entonces:

$$\dim(Nu(L)) + \dim(Im(L)) = \dim(V)$$

Inyectiva y sobreyectiva

Corolario 2.10.

- Una transformación lineal inyectiva conserva la independencia lineal
- Una transformación lineal sobreyectiva cubre todo el codominio

Si una transformación lineal $L: V \rightarrow W$ es inyectiva entonces $Nu(L) = \{0_v\}$

Obtener una transformación a partir de la base

Propiedad 2.11. Si $L : V \rightarrow W$ es una transformación lineal, con V un espacio vectorial de dimensión finita n y $B = \{v_1, \dots, v_n\}$ una base arbitraria de V , entonces L queda completamente determinada por los n vectores $\{L(v_1), \dots, L(v_n)\}$, es decir, por las n imágenes de los vectores de la base.

Esto nos dice que podemos conocer una transformación lineal conociendo solamente como actúa con los vectores de una base cualquiera.

Representación matricial

Consideremos una transformación $L : V \rightarrow W$, con V un espacio vectorial de dimensión n y W otro espacio vectorial (que eventualmente puede ser igual a V) de dimensión m , y sean $B_V = \{v_1, v_2, \dots, v_n\}$ y $B_W = \{w_1, w_2, \dots, w_m\}$ bases de V y W respectivamente.

Primeramente evaluamos como actúa L sobre cada vector de la base B_V y luego escribiremos al vector resultante (que pertenece al subespacio W) en términos de los vectores de la base B_W . En efecto,

$$L(v_j) = w = a_{1j}w_1 + a_{2j}w_2 + \dots + a_{ij}w_i + \dots + a_{mj}w_m$$

Entonces, con las coordenadas a_{ij} formamos la columna j de la matriz A que representará a L en las bases B_V y B_W , es decir:

$$[L]_{B_V B_W} = A = \begin{pmatrix} a_{11} & \dots & a_{1n} \\ a_{21} & \dots & a_{2n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \dots & a_{mn} \end{pmatrix}$$

En el caso especial las transformaciones entre espacios de $\mathbb{R}^n$ tenemos la propiedad extra que dice que aplicar la transformación a un vector es lo mismo que multiplicar al vector por la matriz asociada.

Esto es,

Sea $L : \mathbb{R}^n \rightarrow \mathbb{R}^m$ y sea A una matriz asociada, entonces $L(v) = A \cdot v$
(obviamente v debe estar expresado en la misma base usada para hallar A).

Para obtener la **representación matricial** de una transformación lineal $L : V \rightarrow W$, los pasos estándar son los siguientes:

1. Fijar una base del dominio

Elegir una base $B = \{v_1, \dots, v_n\}$ de V .

(Si no se aclara, normalmente se usa la base canónica).

2. Fijar una base del codominio

Elegir una base $C = \{w_1, \dots, w_m\}$ de W .

(También suele ser la base canónica si no se indica otra).

3. Aplicar la transformación a los vectores de la base del dominio

Calcular:

$$L(v_1), L(v_2), \dots, L(v_n)$$

4. Expresar cada imagen en coordenadas respecto de la base del codominio

Para cada i , escribir:

$$L(v_i) = a_{1i}w_1 + a_{2i}w_2 + \dots + a_{mi}w_m$$

5. Construir la matriz

La matriz de L en las bases B y C es:

$$[L]_{C \leftarrow B} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}$$

donde la **columna i** son las coordenadas de $L(v_i)$.

6. Chequeo rápido

Verificar que:

- La matriz es de tamaño $m \times n$.
- $L(x) = A[x]_B$ se cumple para algún vector de prueba.

